Guía para presentar el código de ML

TI3002C – Etapa 5.1 · Jaime Hernández González (A00840312) · Equipo 6 · Jueves 22 de octubre, 16:30, con Karen (CETEC Sur 5° piso)

1. La idea en 30 segundos

> DanuStore planea su inventario con un pronóstico (`units_expected`) que se equivoca ~470 %: siempre espera unas 6 veces más de lo que vende. Hice dos modelos de **regresión** (Random Forest y XGBoost) que pronostican las **unidades vendidas del siguiente mes** por producto y región, usando las ventas de los últimos 3 meses, la región, la categoría y el mes. Random Forest se equivoca ~6 % a un mes y ~10 % si pronostica 4 meses seguidos. Encontré también que las ventas de 2025 son casi una copia de las de 2024, lo que hace los resultados optimistas.

2. Guion de 5 minutos (qué mostrar en el notebook)

Tiempo	Sección	Qué decir
0:00–0:45	Encabezado y 2.2	"El problema: el pronóstico actual es plano y muy inflado (gráfica azul vs. naranja). Las ventas reales sí tienen temporada: noviembre y diciembre suben."
0:45–1:45	3.1, 3.2 y 3.3	"Creé las ventas de los 3 meses anteriores. Excluí las variables que se calculan con las ventas del mismo mes (fuga de información), el precio (identifica al producto) y las ventas del año pasado (son casi idénticas)."
1:45–2:15	4, 5 y 6	"Codifiqué región y categoría con One-Hot. No normalicé porque son modelos de árboles. Hice 3 particiones por tiempo: 80/20, 70/30 y 60/40."
2:15–3:30	8, 9, 10 y 10.1	"Probé 3 configuraciones de cada modelo en cada partición (18 modelos). Random Forest gana en las tres. La validación de mayo a agosto confirmó las mismas configuraciones."
3:30–4:20	11 y 13	"Residuales centrados en 0. A un mes el error es ~6 %; pronosticando 4 meses seguidos sube a 9.9 % en el bloque y 12.3 % en diciembre. Todo muy por debajo del 468 % actual."
4:20–5:00	14	"Limitante principal: copiar el año anterior da 0.3 % porque los datos se repiten. Por eso los resultados son optimistas y hay que validar con datos nuevos."

3. Qué hace cada sección del código

1–2. Librerías, datos y exploración

- `pd.read_csv` carga el archivo. `isnull().sum()` y `duplicated()` revisan nulos y duplicados (no hay).
- `describe()` da promedio, mínimo, máximo, etc. Las gráficas muestran que las ventas tienen sesgo a la derecha y que CDMX, Monterrey y Guadalajara venden más.
- `map(meses)` convierte "January" en 1, etc. `pd.to_datetime` crea una fecha para poder ordenar en el tiempo.

3. Selección de variables

- `groupby(['product_id','region'])['units_sold'].shift(1)`: para cada producto en cada región, toma la venta del mes anterior. `shift(2)` y `shift(3)` hacen lo mismo con 2 y 3 meses antes.
- El mapa de calor (Spearman) muestra qué variables se relacionan más con las ventas: las ventas pasadas (~0.94).
- **Dos métodos de selección:** correlación (sección 3.3) e importancia de variables del Random Forest (sección 11).

4–5. Codificación y normalización

- `pd.get_dummies` crea una columna de 0/1 por cada región, categoría y subcategoría (One-Hot Encoding).
- No se normaliza: los árboles usan reglas como "¿ventas > 150?", que no cambian con la escala.

6–7. Particiones, métricas y líneas base

- `datos['fecha'] < corte` es el entrenamiento; `>= corte` es la prueba. Es partición **por tiempo**, no aleatoria.

- La función `evaluar` calcula MAE (error promedio en unidades), RMSE (castiga errores grandes), WAPE (error total ÷ ventas, en %) y R^2 (qué tanto explica el modelo).
- Líneas base: pronóstico actual, "igual que el mes pasado" e "igual que hace un año".

8–9. Los dos modelos

- `opciones_rf` y `opciones_xgb` son diccionarios: a la izquierda el nombre de la configuración, a la derecha el modelo.
- Dos ciclos `for`: uno recorre las particiones y otro las configuraciones. En cada vuelta: `fit` (entrenar), `predict` (pronosticar), `evaluar` (métricas) y se guarda en `resultados`.

10. Comparación y validación

- `pivot_table` arma la tabla resumen: una fila por modelo, una columna por partición, con el menor error.
- 10.1: se entrena hasta abril 2025 y se mide en mayo–agosto (validación). Se elige automáticamente la configuración con menor error con `sort_values` + `iloc[0]` (la primera fila).

11. Resultados del mejor modelo

- Se entrena el modelo elegido y se grafica real vs. pronóstico por mes.
- `graficar_residuales` es una función que hace 3 gráficas: real vs. estimado (puntos sobre la línea roja = buen modelo), histograma de errores (centrado en 0) y errores vs. estimado (sin patrón).
- Error por región y las 10 variables más importantes.

12. Impacto del preprocesamiento

- Se entrena el mismo modelo con 4 grupos de variables. `clone()` hace una copia del modelo sin entrenar para no "ensuciar" el modelo elegido.
- Resultado: sin ventas pasadas 22.6 %; con ellas 6.0 %. Agregar el precio casi no cambia (5.9 %).

13. Pronóstico recursivo (varios meses)

- Se "borran" las ventas desde septiembre. Se pronostica septiembre, ese pronóstico se guarda como si fuera la venta real, se recalculan las ventas pasadas y se pronostica octubre, y así hasta diciembre.
- Es lo que pasaría si DanuStore planea 4 meses desde agosto. El error crece: 5.8 % → 9.4 % → 10.9 % → 12.3 %.

4. Números que debes saber de memoria

Qué	Valor
Error del pronóstico actual (units_expected)	~468 % (WAPE)
Random Forest a un mes (80/20 / 70/30 / 60/40)	5.98 % / 6.07 % / 6.12 %
XGBoost a un mes (80/20 / 70/30 / 60/40)	6.58 % / 6.97 % / 7.05 %
Random Forest, bloque sep–dic (recursivo)	9.91 %
Random Forest, diciembre (4 meses adelante)	12.26 %
Copiar el mismo mes del año anterior	~0.3 %
Registros 2025 idénticos a 2024	76.6 %
Sin ventas pasadas / con ventas pasadas	22.6 % / 6.0 %
MAE de Random Forest (80/20)	13.31 unidades
Mejor configuración RF / XGB	100 árboles sin límite / 800 árboles, lr 0.03, profundidad 8

5. Preguntas probables y cómo responder

¿Qué tipo de modelo es?

Regresión supervisada: predice un número (unidades vendidas) a partir de ejemplos con la respuesta conocida.

¿Cuál es la diferencia entre Random Forest y XGBoost?

Random Forest entrena muchos árboles independientes y promedia sus resultados. XGBoost construye árboles uno tras otro, y cada uno corrige los errores del anterior.

¿Por qué no normalizaste?

Porque los árboles separan los datos con reglas tipo "¿ventas > 150?", que dan lo mismo en cualquier escala. Se necesitaría en KNN, regresión regularizada o redes neuronales.

¿Por qué la partición es por tiempo y no aleatoria?

Porque quiero pronosticar el futuro. Si la partición fuera aleatoria, el modelo entrenaría con meses posteriores a los que pronostica y los resultados saldrían inflados.

¿Qué modelo y división funcionaron mejor?

Random Forest, en las tres particiones. Las particiones dan resultados muy parecidos; como evalúan meses distintos, no digo que una sea mejor, solo que el modelo es estable.

¿Qué impacto tuvo el preprocesamiento?

Crear las ventas de los 3 meses anteriores bajó el error de 22.6 % a 6 %. Excluir las variables con fuga evita un modelo perfecto pero inútil.

¿Y el ajuste de hiperparámetros?

Las configuraciones con árboles más limitados tuvieron más error (en Random Forest, de 6 % a 12 %). Comparé configuraciones completas, así que no atribuyo el cambio a un solo parámetro.

Si copiar el año pasado da 0.3 %, ¿para qué el modelo?

Porque en estos datos 2025 es casi una copia de 2024, y eso no es normal en ventas reales. Construí los modelos sin esa variable como decisión experimental, para que dependan de las ventas recientes. Lo reporto como hallazgo de calidad de datos y queda pendiente validar con datos nuevos.

¿Por qué quitaste el precio?

Porque cada producto tiene un precio único, entonces el modelo lo usaba para reconocer el producto y "recordar" sus ventas. Quitarlo casi no cambia el error (5.98 % vs. 5.87 %).

¿Qué es WAPE?

Error total dividido entre las ventas totales. Un WAPE de 6 % significa que el pronóstico se equivoca en 6 de cada 100 unidades vendidas.

¿Qué significan los residuales?

Son real menos estimado. Están centrados en 0, así que el modelo no tiende a sobrestimar ni subestimar.

¿Qué es el pronóstico recursivo?

Pronosticar varios meses seguidos usando mis propios pronósticos como entrada. Es más realista para planear, y por eso el error sube de 6 % a ~10 %.

> **Limitantes que conviene decir tú antes de que te pregunten:** (1) 2025 repite a 2024, así que los errores son optimistas; (2) solo hay ventas de clientes registrados; (3) el error crece con el horizonte; (4) no sirve para productos nuevos sin 3 meses de historial; (5) los meses de prueba se vieron durante el análisis exploratorio.