Resumen: mi código de Machine Learning

TI3002C – Etapa 5.1 · Jaime Hernández González (A00840312) · Equipo 6 · DanuStore

> **En una frase:** hice un modelo que aprende de las ventas pasadas para adivinar cuántas piezas se van a vender el próximo mes, y se equivoca muchísimo menos que el pronóstico que usa DanuStore hoy.

1. El problema

DanuStore decide cuánta ropa mandar a cada tienda con un pronóstico (*units_expected*). Ese pronóstico **espera vender casi 6 veces más** de lo que realmente vende: solo se vende el **17 %** de lo esperado. Resultado: le sobra mucho inventario.

Mi objetivo: pronosticar mejor las **unidades vendidas** de cada producto, en cada región, cada mes. Es un problema de **regresión** (adivinar un número).

2. Los datos y lo que vi

- Base mensual: 130 productos × 7 regiones × 24 meses (2024–2025) = 21,840 renglones. Sin datos vacíos ni repetidos.
- **Temporada:** todas las categorías venden ~21–25 % más en noviembre y diciembre, y menos en febrero.
- **Lo que más vende:** CDMX, Monterrey y Guadalajara; la categoría Casual Wear (29 %).
- **El pronóstico falla en todo:** en todas las categorías se vende solo el 15–18 % de lo esperado.
- ⚠️ **Hallazgo raro:** las ventas de 2025 son **casi una copia** de las de 2024 (77 % idénticas).

3. Las pistas del modelo (selección de variables)

Pista	¿Se usa?	Por qué
Ventas de los 3 meses anteriores y su promedio	✅	La mejor pista (correlación 0.93–0.95)
Mes	✅	Captura la temporada (nov–dic)
Región, categoría, subcategoría	✅	Distinguen zonas y tipos de producto
Ventas acumuladas, cumplimiento, etc.	❌	Son "trampa": ya traen la respuesta escondida
Precio	❌	Cada producto tiene un precio único; servía para memorizar
Ventas del año pasado	❌	2025 copia a 2024; el modelo solo copiaría

- **Correlación:** mide qué tanto se mueven juntas dos cosas (de −1 a 1). Usé **Spearman** porque no se deja engañar por valores extremos.
- **Codificación (One-Hot):** convertí región y categoría en columnas de 0 y 1, porque la computadora solo entiende números.
- **Normalización:** no se necesita, porque los árboles hacen preguntas tipo "¿vendió más de 150?" y la escala no les afecta.

4. Los dos modelos

Modelo	Cómo funciona
🌳 **Random Forest**	Hace 100 árboles de decisión (cadenas de preguntas de sí/no), cada uno con datos un poco distintos, y **promedia** sus respuestas. Como preguntarle a 100 personas y quedarte con el promedio.
🚀 **XGBoost**	Hace árboles **uno tras otro**: cada uno corrige los errores del anterior. Como un alumno que revisa sus errores y lo vuelve a intentar.

Hiperparámetros = las "perillas" que configuro antes de entrenar: número de árboles, profundidad (cuántas preguntas seguidas) y, en XGBoost, el *learning rate* (qué tan fuerte corrige cada árbol). Probé **3 configuraciones** de cada modelo.

5. Cómo los probé

1. **Partición por tiempo:** el modelo estudia con los meses viejos y presenta el examen con los más recientes, que nunca vio. No es al azar, porque queremos pronosticar el futuro.
2. **3 particiones:** 80/20, 70/30 y 60/40. En total, 18 modelos.
3. **Examen de práctica (validación):** para elegir la mejor configuración sin hacer trampa, entrené hasta abril 2025 y probé en mayo–agosto 2025. Ganaron **Random Forest con 100 árboles sin límite** y **XGBoost con 800 árboles**.

6. Cómo medí el error (métricas)

Métrica	Pregunta que responde	Random Forest
MAE	¿Por cuántas piezas me equivoco en promedio?	13 piezas
RMSE	¿Me equivoco feo a veces? (castiga errores grandes)	21 piezas
WAPE	¿De cada 100 piezas, en cuántas me equivoco? (la principal)	**6**
R^2	¿Qué tanto explica el modelo? (1 = perfecto)	0.99

7. Resultados

Método	Error (WAPE)	En palabras
Pronóstico actual de DanuStore	468 %	Espera ~6 veces lo que se vende (R^2 = −32: peor que usar el promedio)
"Vendo lo mismo que el mes pasado"	~19 %	Método simple
XGBoost	6.6 %	Bueno, pero falla más en regiones chicas
Random Forest 🏆	**6.0 %**	El mejor y el más parejo entre regiones (5–8 %)
"Vendo lo mismo que el año pasado"	0.3 %	Casi perfecto solo porque los datos se repiten

- **Estable:** en las 3 particiones el error es casi igual (5.98 %, 6.07 %, 6.12 %).
- **Residuales** (real − pronóstico): centrados en 0. El modelo no tiende a exagerar ni a quedarse corto.
- **Lo que más usa el modelo:** el promedio de los últimos 3 meses (~92 %) y el mes (temporada).
- **Preparar los datos sí importó:** sin las ventas pasadas el error es 22.6 %; con ellas, 6 %.
- **Hiperparámetros:** los árboles muy limitados (podados) tuvieron el doble de error (~12 %), porque necesitan distinguir 910 combinaciones de producto y región.
- **Varios meses seguidos** (usando sus propios pronósticos, como planearía DanuStore desde agosto): el error sube poco a poco, 6 % → 9 % → 11 % → 12 %, y en el bloque de 4 meses queda en **~10 %**. Sigue muy por debajo del 468 % actual.

8. Lo que le sirve a DanuStore

- Planear su inventario con lo que **realmente** se va a vender, no con un número inflado.
- Conocer cómo se comportan sus productos: temporada de nov–dic y qué categorías y regiones venden más.
- Reducir la ropa que le sobra en bodega.

> **Limitantes (dilas tú antes de que te pregunten):**
>
> 1. **2025 copia a 2024**, así que los resultados se ven mejor de lo que serían en la vida real. Por eso, aquí hasta un modelo que "memoriza" sale bien. Hay que probarlo con datos nuevos.
> 2. Solo hay ventas de **clientes registrados**.
> 3. Mientras más lejos pronostica, más se equivoca (6 % a un mes, 12 % a cuatro meses).
> 4. **No sirve para productos nuevos**, porque necesita 3 meses de historia.

5. Los meses de prueba se vieron durante el análisis, así que falta una evaluación independiente.

9. Respuestas rápidas para la profe

Pregunta	Respuesta corta
¿Qué tipo de modelo es?	Regresión supervisada: aprende de ejemplos con respuesta y adivina un número.
¿Por qué no normalizaste?	Los árboles no dependen de la escala.
¿Por qué partición por tiempo?	Para pronosticar el futuro sin "ver" meses posteriores.
¿Por qué 2 modelos?	Lo piden las instrucciones, y sirve para comparar y confirmar el resultado.
¿Por qué mayo–agosto para validar?	Son los 4 meses justo antes de la prueba final: los más parecidos al futuro y del mismo tamaño.
¿Por qué no graficaste el árbol?	Son 100 árboles de ~8,000 hojas cada uno; sería ilegible. Uso la importancia de variables.
¿Por qué no podaste?	Lo probé: el error subió de 6 % a 12–17 %. Las ramas sí aportan.
¿Por qué no un solo árbol?	Un árbol solo memoriza. Aquí le iría bien porque 2025 repite a 2024, pero con ventas reales fallaría.
Si copiar el año pasado da 0.3 %, ¿para qué el modelo?	Porque los datos se repiten, y eso no es normal en ventas reales. Lo reporto como hallazgo de calidad de datos.

🎤 **Todo en 30 segundos:** "DanuStore espera vender 6 veces más de lo que vende y por eso le sobra inventario. Hice dos modelos que aprenden de las ventas de los últimos 3 meses, la región, el tipo de producto y la temporada. Los probé en meses que no habían visto y elegí la mejor configuración con un examen de práctica. Random Forest ganó: se equivoca en 6 de cada 100 piezas, contra 468 del pronóstico actual, y en ~10 si planea 4 meses seguidos. La limitante es que los datos de 2025 copian a 2024, así que hay que validarlo con datos nuevos."