TI3002C – Etapa 5.1: Código ML

Equipo 6 – Nexxus Consulting Nombre: Jaime Hernández González **Matrícula:** A00840312

Problemática (regresión): pronosticar las **unidades vendidas (`units_sold`)** de cada producto, en cada región y en cada mes, para que DanuStore planee su inventario con un pronóstico más preciso que el que usa hoy (`units_expected`).

Modelos: Random Forest y XGBoost (los dos propuestos en la investigación de la Etapa 5.1).

1. Librerías

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.ensemble import RandomForestRegressor
from xgboost import XGBRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

pd.set_option('display.max_colwidth', None)   # para ver los hiperparámetros completos en las tablas
```

2. Importar datos

Se usa la base **mensual (Nivel Macro)**: 130 productos × 7 regiones × 24 meses (2024–2025).

In [2]:
```
# Si usas Google Drive, monta tu Drive y cambia la ruta:
# from google.colab import drive
# drive.mount('/content/drive')
# df = pd.read_csv('/content/drive/MyDrive/data_DanuStore_Equipo6_Mensual.csv')

df = pd.read_csv('data_DanuStore_Equipo6_Mensual.csv')
print(df.shape)
df.head()
```

```
(21840, 20)
```

Out[2]:

	month	year	product_id	region	units_expected	stock	percentage	units_sold	sales_amount	product_name
0	March	2025	39	Bajío	1057	1735	164.14	107	4045.32	Shirts Product 39
1	October	2025	46	Ciudad de México	1983	3215	162.13	671	49978.14	Pants Product 46
2	May	2025	113	Ciudad de México	2549	4030	158.10	693	52325.53	Boots Product 113
3	February	2025	75	Ciudad de México	1388	2192	157.93	355	23911.75	Jewelry Product 75
4	October	2025	84	Ciudad de México	1458	2298	157.61	467	18204.74	Hats Product 84

2.1 Exploración inicial

Revisamos el tamaño de la base, los tipos de datos, si hay valores nulos o registros duplicados, y las estadísticas básicas de la variable objetivo.

In [3]:
```
print('Filas y columnas:', df.shape)
print('Valores nulos en toda la base:', df.isnull().sum().sum())
print('Registros duplicados:', df.duplicated().sum())
print('Productos:', df['product_id'].nunique(), '| Regiones:', df['region'].nunique(), '|
Categorías:', df['category'].nunique())
df.dtypes
```

```
Filas y columnas: (21840, 20)
Valores nulos en toda la base: 0
Registros duplicados: 0
Productos: 130 | Regiones: 7 | Categorías: 4
```

Out[3]:
```
month                              str
year                             int64
product_id                       int64
region                             str
units_expected                   int64
stock                            int64
percentage                     float64
units_sold                       int64
sales_amount                   float64
product_name                       str
category                           str
subcategory                        str
static_price                   float64
inventory_key                      str
Ventas_Acumuladas_Mensual        int64
Stock_Restante_Mensual           int64
Cumplimiento_Venta_Esperada    float64
Product_Repeat_Purchase_Rate   float64
Venta_Promedio_Diaria          float64
Dias_Cobertura_Inventario      float64
dtype: object
```

In [4]:
```
df[['units_sold', 'units_expected', 'stock', 'static_price']].describe().round(2)
```

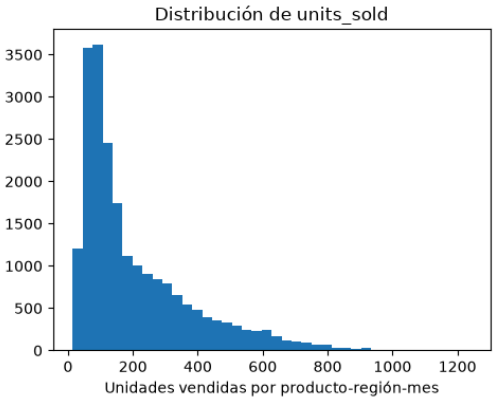
Out[4]:

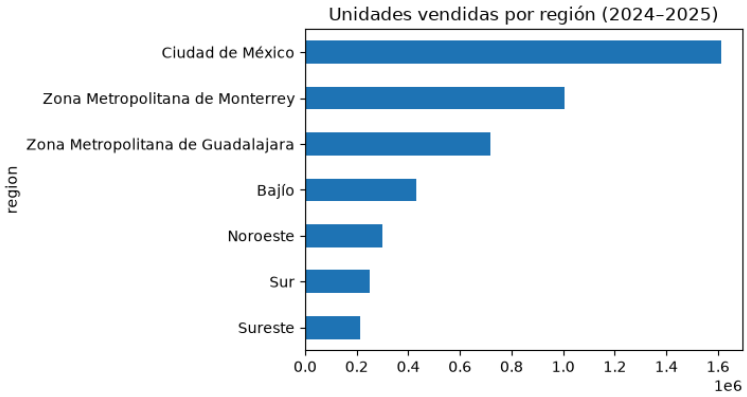
	units_sold	units_expected	stock	static_price
count	21840.00	21840.00	21840.00	21840.00
mean	207.55	1222.49	1358.55	83.64
std	175.59	434.38	566.11	44.36
min	15.00	323.00	120.00	21.99
25%	81.00	888.75	930.00	48.67
50%	138.50	1192.00	1279.00	77.18
75%	286.00	1507.00	1703.00	104.50
max	1240.00	3111.00	4732.00	231.68

In [5]:
```
fig, ax = plt.subplots(1, 2, figsize=(12, 4))

ax[0].hist(df['units_sold'], bins=40)
ax[0].set_title('Distribución de units_sold')
ax[0].set_xlabel('Unidades vendidas por producto-región-mes')

df.groupby('region')['units_sold'].sum().sort_values().plot(kind='barh', ax=ax[1])
ax[1].set_title('Unidades vendidas por región (2024–2025)')
plt.tight_layout()
plt.show()
```





Interpretación: la base no tiene nulos ni duplicados. `units_sold` tiene sesgo a la derecha (la mayoría de los registros vende poco y pocos venden mucho) y las ventas se concentran en CDMX, Monterrey y Guadalajara, por lo que la **región** será una variable importante.

2.2 Preparar la fecha

La columna `month` viene como texto (January, February…). La convertimos a número y creamos una fecha para poder ordenar los datos en el tiempo.

In [6]:
```
meses = {'January': 1, 'February': 2, 'March': 3, 'April': 4, 'May': 5, 'June': 6,
         'July': 7, 'August': 8, 'September': 9, 'October': 10, 'November': 11, 'December': 12}

df['mes'] = df['month'].map(meses)
df['fecha'] = pd.to_datetime(dict(year=df['year'], month=df['mes'], day=1))

# Ordenar por producto, región y fecha
df = df.sort_values(['product_id', 'region', 'fecha']).reset_index(drop=True)
df[['product_id', 'region', 'fecha', 'units_sold', 'units_expected']].head()
```

Out[6]:

	product_id	region	fecha	units_sold	units_expected
0	1	Bajío	2024-01-01	136	1398
1	1	Bajío	2024-02-01	161	1456
2	1	Bajío	2024-03-01	148	1363
3	1	Bajío	2024-04-01	161	1283
4	1	Bajío	2024-05-01	177	1367

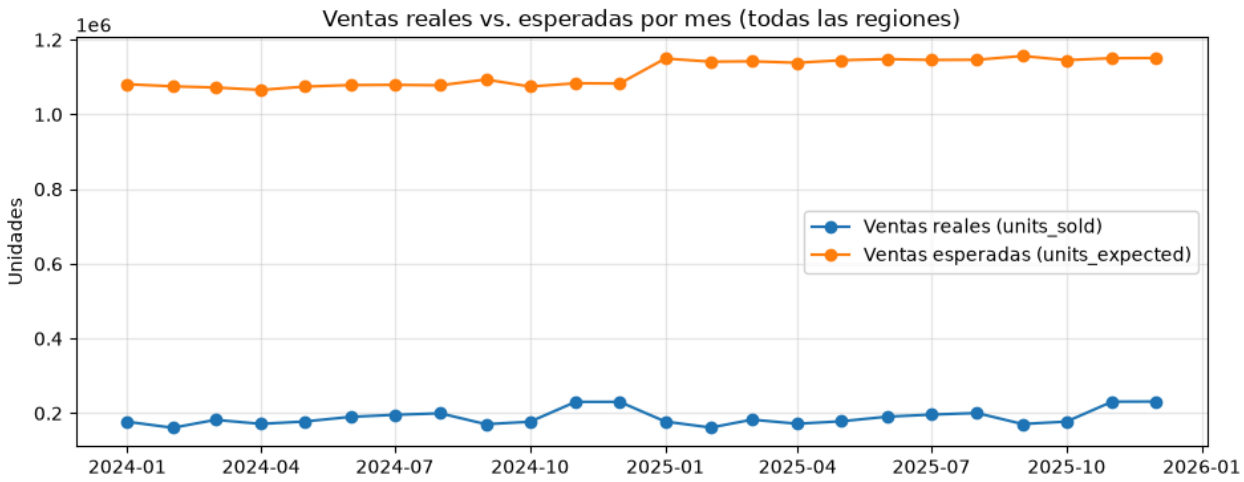
2.3 Las ventas a través del tiempo

Antes de modelar vemos cómo se comportan las ventas reales contra lo que DanuStore esperaba vender.

In [7]:
```
por_mes = df.groupby('fecha')[['units_sold', 'units_expected']].sum()

plt.figure(figsize=(11, 4))
plt.plot(por_mes.index, por_mes['units_sold'], marker='o', label='Ventas reales (units_sold)')
plt.plot(por_mes.index, por_mes['units_expected'], marker='o', label='Ventas esperadas
(units_expected)')
plt.title('Ventas reales vs. esperadas por mes (todas las regiones)')
plt.ylabel('Unidades')
plt.legend()
plt.grid(alpha=0.3)
plt.show()

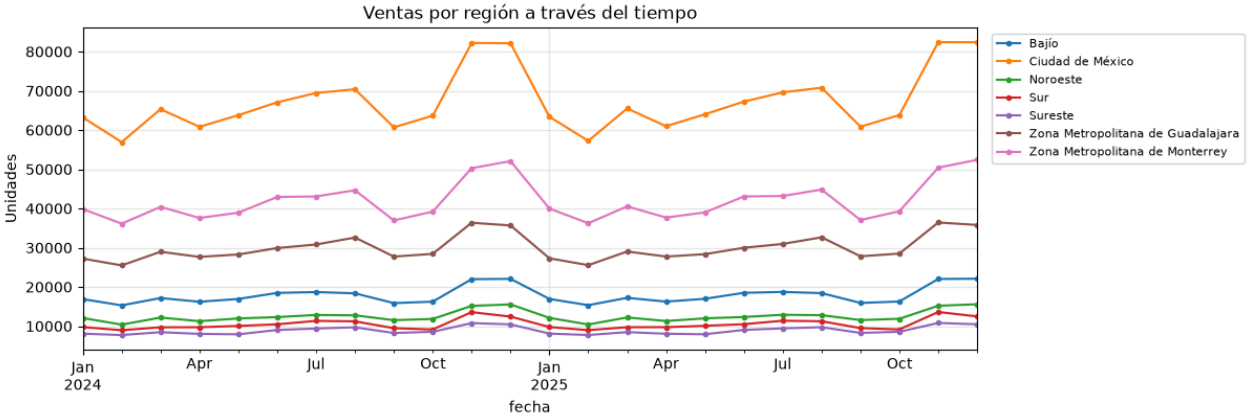
print('Se vendió el', round(por_mes['units_sold'].sum() / por_mes['units_expected'].sum() *
100, 1), '% de lo esperado')
```




```
Se vendió el 17.0 % de lo esperado
```

In [8]:
```python
# Tabla con una fila por mes y una columna por región
por_region_mes = df.pivot_table(index='fecha', columns='region', values='units_sold',
aggfunc='sum')

por_region_mes.plot(figsize=(11, 4), marker='.')
plt.title('Ventas por región a través del tiempo')
plt.ylabel('Unidades')
plt.legend(bbox_to_anchor=(1.01, 1), loc='upper left', fontsize=8)
plt.grid(alpha=0.3)
plt.show()
```



Interpretación: el pronóstico actual (`units_expected`) es casi plano y muy superior a las ventas reales, mientras que las ventas sí tienen picos (noviembre y diciembre) en todas las regiones, y el patrón de 2025 es igual al de 2024. Esto confirma que hace falta un modelo que aprenda el comportamiento real de las ventas.

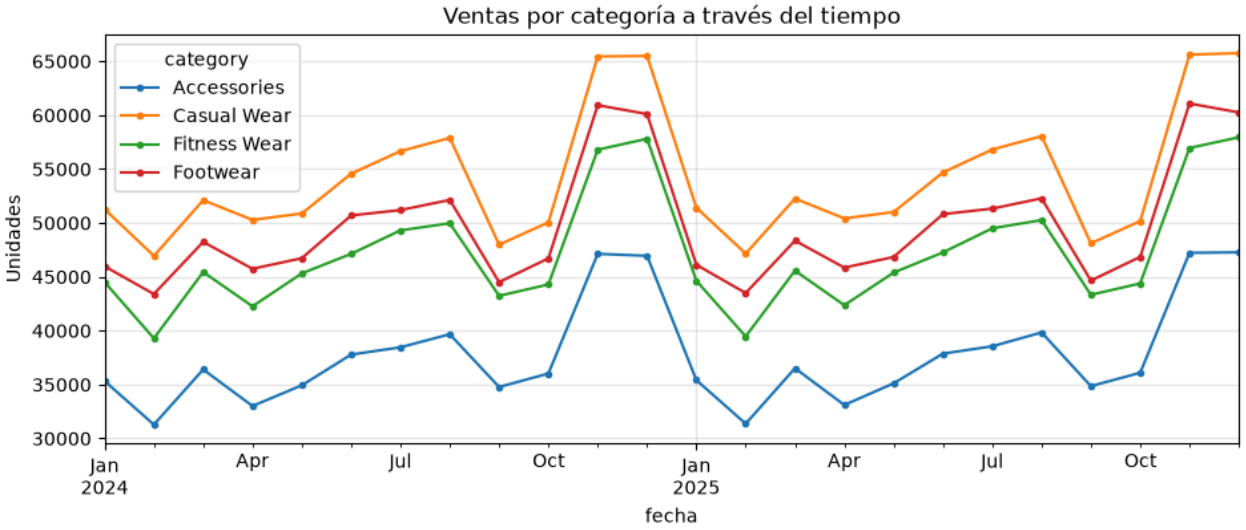
2.4 Comportamiento de los productos por categoría

Para que DanuStore conozca cómo se comportan sus productos, revisamos las ventas de cada categoría a través del tiempo y qué parte de lo esperado se vende en cada una.

In [9]:
```python
# Ventas de cada categoría por mes
por_categoria_mes = df.pivot_table(index='fecha', columns='category', values='units_sold',
aggfunc='sum')

por_categoria_mes.plot(figsize=(11, 4), marker='.')
plt.title('Ventas por categoría a través del tiempo')
plt.ylabel('Unidades')
plt.grid(alpha=0.3)
plt.show()
```

```
# Resumen por categoría
por_categoria = df.groupby('category')[['units_sold', 'units_expected']].sum()
por_categoria['% de las ventas totales'] = (por_categoria['units_sold'] /
por_categoria['units_sold'].sum() * 100).round(1)
por_categoria['% vendido de lo esperado'] = (por_categoria['units_sold'] /
por_categoria['units_expected'] * 100).round(1)
por_categoria.sort_values('% de las ventas totales', ascending=False)
```



Out[9]:

category	units_sold	units_expected	% de las ventas totales	% vendido de lo esperado
Casual Wear	1301064	7243201	28.7	18.0
Footwear	1194283	7762632	26.3	15.4
Fitness Wear	1132457	6306122	25.0	18.0
Accessories	905013	5387310	20.0	16.8

Interpretación:

- **Casual Wear** es la categoría que más vende (28.7 % de las unidades), seguida de Footwear (26.3 %), Fitness Wear (25.0 %) y Accessories (20.0 %).
- Las **cuatro categorías tienen la misma temporada**: suben ~21–25 % sobre su mes promedio en noviembre y diciembre, y bajan ~13–17 % en febrero. Por eso el mes es una variable útil para el modelo.
- En todas se vende solo entre **15 % y 18 % de lo esperado**; Footwear es la más sobrepronosticada (15.4 %). El problema del pronóstico es general, no de una sola categoría.

3. Selección de variables

3.1 Universo de variables

- **Variable objetivo (y):** `units_sold`.
- **Variables candidatas:** `region`, `category`, `subcategory`, `mes`, `static_price` y las **ventas de meses anteriores** (rezagos), que creamos a continuación.

Para pronosticar el mes siguiente solo podemos usar información que **ya conocemos**. Por eso creamos:

- `ventas_mes_anterior`: ventas del mes pasado (t−1).
- `ventas_hace_2` y `ventas_hace_3`: ventas de hace 2 y 3 meses.
- `promedio_3_meses`: promedio de los 3 meses anteriores.

In [10]:
```
# Agrupamos por producto y región para que cada serie use SUS propias ventas pasadas
grupo = df.groupby(['product_id', 'region'])['units_sold']

df['ventas_mes_anterior'] = grupo.shift(1)
df['ventas_hace_2'] = grupo.shift(2)
df['ventas_hace_3'] = grupo.shift(3)
df['promedio_3_meses'] = (df['ventas_mes_anterior'] + df['ventas_hace_2'] +
df['ventas_hace_3']) / 3
df['ventas_hace_12'] = grupo.shift(12)   # mismo mes del año pasado (solo para revisarla)

df[['product_id', 'region', 'fecha', 'units_sold', 'ventas_mes_anterior',
'promedio_3_meses']].head(6)
```

Out[10]:

	product_id	region	fecha	units_sold	ventas_mes_anterior	promedio_3_meses
0	1	Bajío	2024-01-01	136	NaN	NaN
1	1	Bajío	2024-02-01	161	136.0	NaN
2	1	Bajío	2024-03-01	148	161.0	NaN
3	1	Bajío	2024-04-01	161	148.0	148.333333
4	1	Bajío	2024-05-01	177	161.0	156.666667
5	1	Bajío	2024-06-01	136	177.0	162.000000

3.2 Variables que NO se pueden usar

Estas variables se calculan **con las ventas del mismo mes** que queremos pronosticar. Si las usamos, el modelo "haría trampa" (fuga de información) porque en la vida real no las conocemos antes de que termine el mes:

Variable	Por qué se excluye
`Ventas_Acumuladas_Mensual`	Es igual a `units_sold`
`Venta_Promedio_Diaria`	Es `units_sold` ÷ días del mes
`sales_amount`	Es `units_sold` × precio
`Cumplimiento_Venta_Esperada`	Es `units_sold` ÷ `units_expected`
`Dias_Cobertura_Inventario`	Usa la venta promedio diaria
`Stock_Restante_Mensual`	Es stock − `units_sold`

`units_expected` tampoco se usa como variable: se usa como **punto de comparación** (es el pronóstico actual de la empresa).

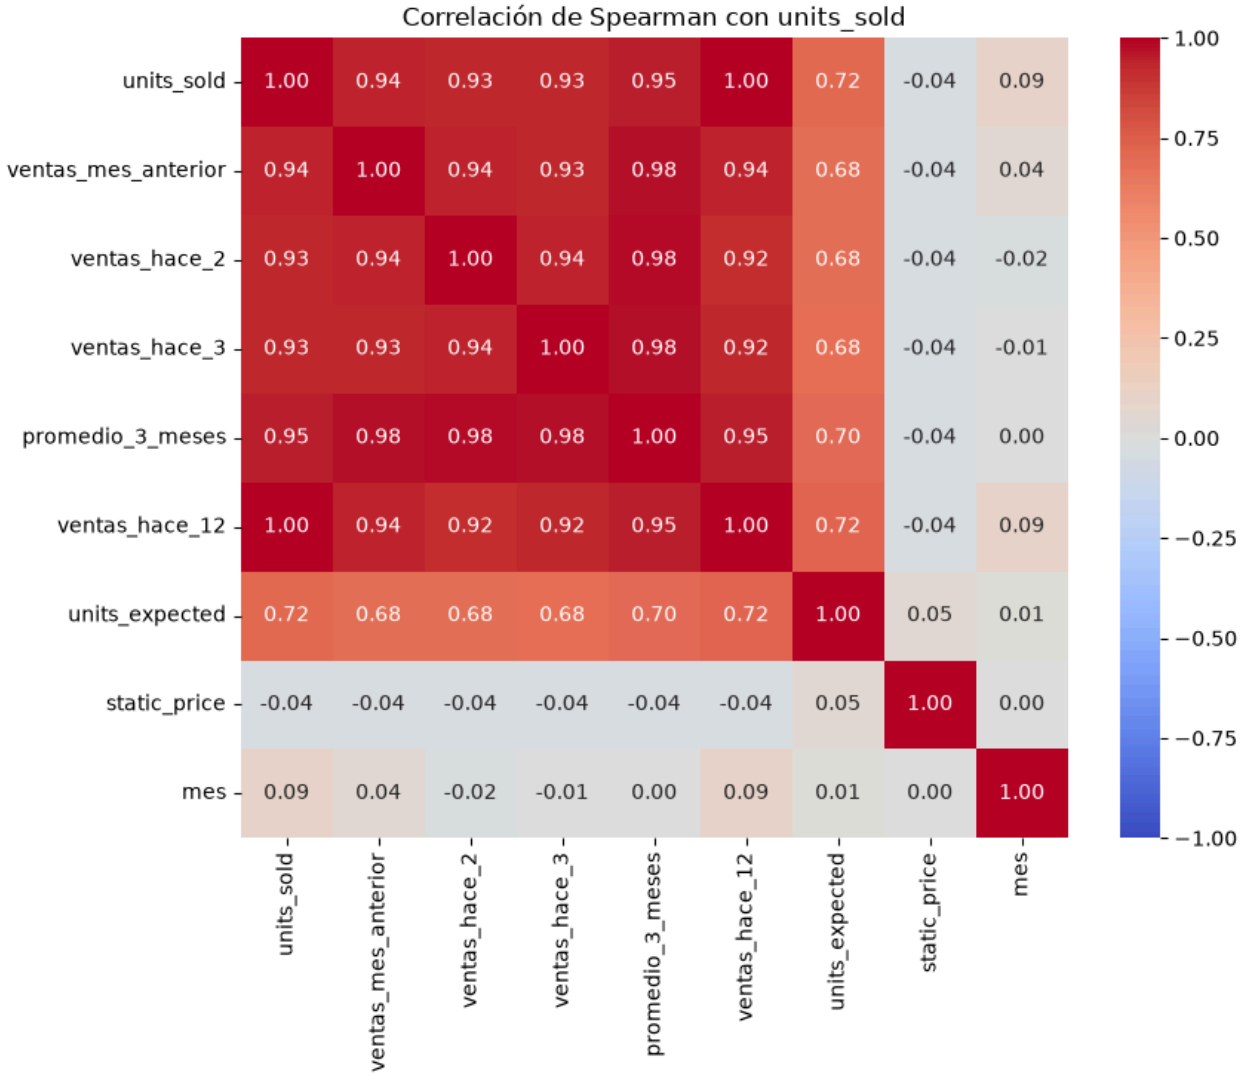
3.3 Correlaciones más importantes

In [11]:
```
variables_numericas = ['units_sold', 'ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3',
                       'promedio_3_meses', 'ventas_hace_12', 'units_expected', 'static_price',
'mes']

correlacion = df[variables_numericas].corr(method='spearman')

plt.figure(figsize=(9, 7))
sns.heatmap(correlacion, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1, vmax=1)
plt.title('Correlación de Spearman con units_sold')
plt.show()

print(correlacion['units_sold'].sort_values(ascending=False).round(3))
```




```
units_sold             1.000
ventas_hace_12         1.000
promedio_3_meses       0.950
ventas_mes_anterior    0.939
ventas_hace_3          0.927
ventas_hace_2          0.927
units_expected         0.715
mes                    0.093
static_price          -0.038
Name: units_sold, dtype: float64
```

In [12]:
```
# ¿Las ventas de 2025 se parecen a las de 2024?
tabla = df.pivot_table(index=['product_id', 'region', 'mes'], columns='year',
values='units_sold')
iguales = (tabla[2024] == tabla[2025]).mean() * 100
print('Registros donde las ventas de 2025 son IGUALES a las de 2024:', round(iguales, 1), '%')
```

```
print('Diferencia promedio entre 2025 y 2024:', round((tabla[2025] - tabla[2024]).abs().mean(),
2), 'unidades')
```

```
Registros donde las ventas de 2025 son IGUALES a las de 2024: 76.6 %
Diferencia promedio entre 2025 y 2024: 0.61 unidades
```

Interpretación y selección:

- Las ventas de los meses anteriores (`ventas_mes_anterior` , `promedio_3_meses`) son las variables más relacionadas con `units_sold` , por eso se seleccionan.
- `units_expected` tiene una correlación menor: ordena bien qué productos venden más, pero no acierta en la cantidad.
- `mes` tiene correlación baja por sí sola, pero se conserva porque los árboles pueden encontrar **combinaciones** (por ejemplo, región × mes, o la temporada de noviembre–diciembre) que una correlación no detecta.
- **`static_price` NO se usa:** cada producto tiene un precio único (ver la celda siguiente), así que el precio funciona como un **identificador del producto**. Como las ventas de 2025 repiten las de 2024, el modelo lo usaría para "recordar" cuánto vendió cada producto en lugar de aprender patrones, y podría depender de que los precios no cambien. Se excluye como **decisión experimental** para reducir esa dependencia; en la sección 12 se comprueba que quitarlo casi no cambia el error.
- **`ventas_hace_12` NO se usa como variable del modelo:** su correlación es prácticamente 1 porque en la base **las ventas de 2025 repiten casi exactamente las de 2024**. Se excluye como **decisión experimental** para evaluar modelos basados en información reciente; su efecto sobre la generalización queda pendiente de validar. Además, solo existe para 2025, lo que dejaría muy pocos meses para entrenar. **Sí se usa como línea base** ("vender lo mismo que hace un año", sección 7.1), porque esa información está disponible al pronosticar. Este hallazgo se reportará al socio formador como una observación sobre la calidad de los datos.

Variables seleccionadas: `region` , `category` , `subcategory` , `mes` , `ventas_mes_anterior` , `ventas_hace_2` , `ventas_hace_3` , `promedio_3_meses` .

In [13]:
```
# ¿El precio identifica al producto?
print('Productos distintos:', df['product_id'].nunique())
print('Precios distintos:', df['static_price'].nunique())
print('¿Cada producto tiene un solo precio?', (df.groupby('product_id')
['static_price'].nunique() == 1).all())
```

```
Productos distintos: 130
Precios distintos: 130
¿Cada producto tiene un solo precio? True
```

4. Codificar variables categóricas

Los modelos solo entienden números. `region` , `category` y `subcategory` son texto, así que se convierten con **One-Hot Encoding** (`pd.get_dummies`): se crea una columna de 0 y 1 por cada categoría.

In [14]:
```
# Quitamos los 3 primeros meses de cada serie (no tienen ventas anteriores para calcular los rezagos)
datos = df.dropna(subset=['promedio_3_meses']).copy()

variables = ['region', 'category', 'subcategory', 'mes',
             'ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3', 'promedio_3_meses']

X = pd.get_dummies(datos[variables], columns=['region', 'category', 'subcategory'], dtype=int)
y = datos['units_sold']

print('Registros:', X.shape[0], '| Columnas después de codificar:', X.shape[1])
X.head()
```

```
Registros: 19110 | Columnas después de codificar: 29
```

Out[14]:

	mes	ventas_mes_anterior	ventas_hace_2	ventas_hace_3	promedio_3_meses	region_Bajío	region_Ciudad de México	region_
3	4	148.0	161.0	136.0	148.333333	1	0	
4	5	161.0	148.0	161.0	156.666667	1	0	
5	6	177.0	161.0	148.0	162.000000	1	0	
6	7	136.0	177.0	161.0	158.000000	1	0	
7	8	143.0	136.0	177.0	152.000000	1	0	

5 rows × 29 columns

5. Normalización / estandarización

No es necesaria. Random Forest y XGBoost son modelos de **árboles de decisión**: separan los datos con reglas del tipo "¿ventas del mes anterior > 150?". Esas reglas funcionan igual si la variable está en unidades, en miles o estandarizada, así que la escala no cambia el resultado. La normalización sí sería necesaria en modelos que comparan distancias o usan coeficientes, como KNN, regresión lineal regularizada (Ridge/Lasso) o redes neuronales.

6. Partición de los datos (temporal)

Como queremos pronosticar el **futuro**, no se usa una partición aleatoria: se entrena con los meses más antiguos y se prueba con los más recientes. Se prueban **tres particiones** (los datos con rezagos van de abril 2024 a diciembre 2025, 21 meses):

- **80/20:** entrenar hasta agosto 2025 (17 meses) y probar con septiembre–diciembre 2025 (4 meses).
- **70/30:** entrenar hasta junio 2025 (15 meses) y probar con julio–diciembre 2025 (6 meses).
- **60/40:** entrenar hasta abril 2025 (13 meses) y probar con mayo–diciembre 2025 (8 meses).

Importante: en las secciones 7 a 12 la evaluación es **a un mes**: para pronosticar cada mes de prueba se usan las ventas **reales** del mes anterior, como pasaría si DanuStore pronostica cada mes cuando ya cerró el anterior. El pronóstico de varios meses desde un solo punto, sin conocer las ventas intermedias, se evalúa en la sección 13.

Las tres particiones tienen **periodos de prueba distintos y que se enciman** (septiembre–diciembre, julio–diciembre y mayo–diciembre), así que sus errores no se pueden comparar directamente para decir que una es "mejor": las diferencias pueden deberse a los meses que se evalúan (por ejemplo, la temporada de noviembre–diciembre). Sirven para ver si el modelo es **estable** con distintas cantidades de datos.

In [15]:
```
particiones = {
    '80/20': '2025-09-01',
    '70/30': '2025-07-01',
    '60/40': '2025-05-01',
}

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    print(nombre, '-> entrenamiento:', entrenamiento.sum(), 'registros | prueba:',
(~entrenamiento).sum(), 'registros')
```

```
80/20 -> entrenamiento: 15470 registros | prueba: 3640 registros
70/30 -> entrenamiento: 13650 registros | prueba: 5460 registros
60/40 -> entrenamiento: 11830 registros | prueba: 7280 registros
```

7. Métricas de evaluación

- **MAE:** error promedio en unidades.
- **RMSE:** como el MAE, pero castiga más los errores grandes.
- **WAPE:** error total ÷ ventas totales (en %). Es la métrica principal porque se lee fácil: "el pronóstico se equivoca X% de lo que se vende".
- **R^2:** qué tanto de la variación de las ventas explica el modelo (1 = perfecto).

In [16]:
```
def evaluar(y_real, y_pred):
    mae = mean_absolute_error(y_real, y_pred)
    rmse = np.sqrt(mean_squared_error(y_real, y_pred))
    wape = np.abs(y_real - y_pred).sum() / y_real.sum() * 100
    r2 = r2_score(y_real, y_pred)
    # float() convierte los resultados a números normales de Python para que se impriman
limpios
    return {'MAE': round(float(mae), 2), 'RMSE': round(float(rmse), 2), 'WAPE (%)':
round(float(wape), 2), 'R2': round(float(r2), 3)}
```

7.1 Puntos de comparación (líneas base)

Un modelo solo sirve si le gana a lo que ya existe:

1. **Pronóstico actual de DanuStore** (`units_expected`).
2. **Modelo ingenuo:** "este mes voy a vender lo mismo que el mes pasado".
3. **Ingenuo estacional:** "este mes voy a vender lo mismo que en el mismo mes del año pasado".

In [17]:
```
resultados = []

for nombre, corte in particiones.items():
    prueba = datos['fecha'] >= corte
    fila = evaluar(y[prueba], datos.loc[prueba, 'units_expected'])
    fila['Modelo'] = 'Pronóstico actual (units_expected)'
    fila['Partición'] = nombre
    fila['Hiperparámetros'] = '-'
    resultados.append(fila)

    fila = evaluar(y[prueba], datos.loc[prueba, 'ventas_mes_anterior'])
    fila['Modelo'] = 'Ingenuo (mes anterior)'
    fila['Partición'] = nombre
    fila['Hiperparámetros'] = '-'
    resultados.append(fila)

    fila = evaluar(y[prueba], datos.loc[prueba, 'ventas_hace_12'])
    fila['Modelo'] = 'Ingenuo estacional (mismo mes del año anterior)'
    fila['Partición'] = nombre
    fila['Hiperparámetros'] = '-'
    resultados.append(fila)
```

```
pd.DataFrame(resultados)[['Partición', 'Modelo', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)',
'R2']]
```

Out[17]:

	Partición	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
0	80/20	Pronóstico actual (units_expected)	-	1042.04	1093.44	467.95	-32.190
1	80/20	Ingenuo (mes anterior)	-	44.15	66.71	19.83	0.876
2	80/20	Ingenuo estacional (mismo mes del año anterior)	-	0.64	4.12	0.29	1.000
3	70/30	Pronóstico actual (units_expected)	-	1041.87	1093.51	471.23	-33.236
4	70/30	Ingenuo (mes anterior)	-	41.23	62.18	18.65	0.889
5	70/30	Ingenuo estacional (mismo mes del año anterior)	-	0.68	4.43	0.31	0.999
6	60/40	Pronóstico actual (units_expected)	-	1045.73	1097.63	483.00	-35.065
7	60/40	Ingenuo (mes anterior)	-	39.34	59.34	18.17	0.895
8	60/40	Ingenuo estacional (mismo mes del año anterior)	-	0.64	4.04	0.30	1.000

Interpretación de las líneas base:

- El pronóstico actual de DanuStore se equivoca ~470 %, y repetir el mes pasado ~19 %.
- **Repetir el mismo mes del año pasado se equivoca menos del 0.5 %.** Esto no necesariamente es porque sea un buen método en general, sino porque **en esta base las ventas de 2025 son casi una copia de las de 2024** (sección 3.3). Es el método con menor error entre los evaluados, y esta repetición es la principal limitante del análisis: se reportará al socio formador.
- Los modelos de ML se construyen **sin** las ventas del año anterior como decisión experimental: así dependen del nivel de ventas reciente, la región y la temporada, y no de copiar el año anterior. Si esto realmente funciona mejor cuando las ventas no se repiten es algo que **queda pendiente de validar** con datos nuevos.

8. Modelo 1: Random Forest

Entrena muchos árboles de decisión, cada uno con una muestra aleatoria de los datos, y **promedia** sus pronósticos.

Hiperparámetros que se prueban (3 configuraciones):

- `n_estimators` : número de árboles.
- `max_depth` : profundidad máxima de cada árbol (None = sin límite).
- `min_samples_leaf` : mínimo de registros en cada hoja (evita que el árbol memorice).

In [18]:

```
# Las 3 configuraciones de Random Forest: el texto es el nombre y a la derecha está el modelo
opciones_rf = {
    'n_estimators=100, max_depth=None, min_samples_leaf=1':
RandomForestRegressor(n_estimators=100, max_depth=None, min_samples_leaf=1, random_state=42),
    'n_estimators=200, max_depth=15, min_samples_leaf=2':
RandomForestRegressor(n_estimators=200, max_depth=15, min_samples_leaf=2, random_state=42),
    'n_estimators=300, max_depth=8, min_samples_leaf=5':
RandomForestRegressor(n_estimators=300, max_depth=8, min_samples_leaf=5, random_state=42),
}

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    prueba = datos['fecha'] >= corte

    for hiperparametros, modelo in opciones_rf.items():
        modelo.fit(X[entrenamiento], y[entrenamiento])     # entrenar
        prediccion = modelo.predict(X[prueba])               # pronosticar

        fila = evaluar(y[prueba], prediccion)                # calcular las métricas
        fila['Modelo'] = 'Random Forest'
        fila['Partición'] = nombre
```

```
        fila['Hiperparámetros'] = hiperparametros
        resultados.append(fila)

tabla = pd.DataFrame(resultados)
tabla[tabla['Modelo'] == 'Random Forest'][['Partición', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE
(%)', 'R2']]
```

Out[18]:

	Partición	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
9	80/20	n_estimators=100, max_depth=None, min_samples_leaf=1	13.31	20.80	5.98	0.988
10	80/20	n_estimators=200, max_depth=15, min_samples_leaf=2	16.57	25.07	7.44	0.983
11	80/20	n_estimators=300, max_depth=8, min_samples_leaf=5	26.93	38.72	12.10	0.958
12	70/30	n_estimators=100, max_depth=None, min_samples_leaf=1	13.42	20.92	6.07	0.987
13	70/30	n_estimators=200, max_depth=15, min_samples_leaf=2	17.55	26.18	7.94	0.980
14	70/30	n_estimators=300, max_depth=8, min_samples_leaf=5	27.25	39.35	12.33	0.956
15	60/40	n_estimators=100, max_depth=None, min_samples_leaf=1	13.26	20.76	6.12	0.987
16	60/40	n_estimators=200, max_depth=15, min_samples_leaf=2	17.52	25.93	8.09	0.980
17	60/40	n_estimators=300, max_depth=8, min_samples_leaf=5	27.08	39.15	12.51	0.954

9. Modelo 2: XGBoost

Construye árboles **uno tras otro**; cada árbol nuevo corrige los errores de los anteriores.

Hiperparámetros que se prueban (3 configuraciones):

- `n_estimators` : número de árboles.
- `learning_rate` : qué tanto corrige cada árbol (más bajo = más lento pero más cuidadoso).
- `max_depth` : profundidad máxima de cada árbol.

In [19]:

```
opciones_xgb = {
    'n_estimators=300, learning_rate=0.1, max_depth=6':  XGBRegressor(n_estimators=300,
learning_rate=0.1, max_depth=6, random_state=42),
    'n_estimators=500, learning_rate=0.05, max_depth=4': XGBRegressor(n_estimators=500,
learning_rate=0.05, max_depth=4, random_state=42),
    'n_estimators=800, learning_rate=0.03, max_depth=8': XGBRegressor(n_estimators=800,
learning_rate=0.03, max_depth=8, random_state=42),
}

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    prueba = datos['fecha'] >= corte

    for hiperparametros, modelo in opciones_xgb.items():
        modelo.fit(X[entrenamiento], y[entrenamiento])
        prediccion = modelo.predict(X[prueba])

        fila = evaluar(y[prueba], prediccion)
        fila['Modelo'] = 'XGBoost'
        fila['Partición'] = nombre
        fila['Hiperparámetros'] = hiperparametros
        resultados.append(fila)

tabla = pd.DataFrame(resultados)
tabla[tabla['Modelo'] == 'XGBoost'][['Partición', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)',
'R2']]
```

Out[19]:

	Partición	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
18	80/20	n_estimators=300, learning_rate=0.1, max_depth=6	20.23	27.61	9.09	0.979
19	80/20	n_estimators=500, learning_rate=0.05, max_depth=4	26.26	37.27	11.79	0.961
20	80/20	n_estimators=800, learning_rate=0.03, max_depth=8	14.64	20.54	6.58	0.988
21	70/30	n_estimators=300, learning_rate=0.1, max_depth=6	20.60	28.31	9.32	0.977
22	70/30	n_estimators=500, learning_rate=0.05, max_depth=4	26.51	37.87	11.99	0.959
23	70/30	n_estimators=800, learning_rate=0.03, max_depth=8	15.42	21.84	6.97	0.986
24	60/40	n_estimators=300, learning_rate=0.1, max_depth=6	20.35	27.86	9.40	0.977
25	60/40	n_estimators=500, learning_rate=0.05, max_depth=4	25.97	36.91	11.99	0.959
26	60/40	n_estimators=800, learning_rate=0.03, max_depth=8	15.26	21.12	7.05	0.987

10. Comparación de todos los modelos

In [20]:
```
tabla_final = pd.DataFrame(resultados)[['Partición', 'Modelo', 'Hiperparámetros', 'MAE',
'RMSE', 'WAPE (%)', 'R2']]
tabla_final = tabla_final.sort_values(['Partición', 'WAPE (%)'])
tabla_final
```

Out[20]:

	Partición	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
8	60/40	Ingenuo estacional (mismo mes del año anterior)	-	0.64	4.04	0.30	1.000
15	60/40	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.26	20.76	6.12	0.987
26	60/40	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	15.26	21.12	7.05	0.987
16	60/40	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	17.52	25.93	8.09	0.980
24	60/40	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	20.35	27.86	9.40	0.977
25	60/40	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	25.97	36.91	11.99	0.959
17	60/40	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	27.08	39.15	12.51	0.954
7	60/40	Ingenuo (mes anterior)	-	39.34	59.34	18.17	0.895
6	60/40	Pronóstico actual (units_expected)	-	1045.73	1097.63	483.00	-35.065
5	70/30	Ingenuo estacional (mismo mes del año anterior)	-	0.68	4.43	0.31	0.999
12	70/30	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.42	20.92	6.07	0.987
23	70/30	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	15.42	21.84	6.97	0.986
13	70/30	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	17.55	26.18	7.94	0.980
21	70/30	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	20.60	28.31	9.32	0.977
22	70/30	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	26.51	37.87	11.99	0.959
14	70/30	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	27.25	39.35	12.33	0.956
4	70/30	Ingenuo (mes anterior)	-	41.23	62.18	18.65	0.889
3	70/30	Pronóstico actual (units_expected)	-	1041.87	1093.51	471.23	-33.236
2	80/20	Ingenuo estacional (mismo mes del año anterior)	-	0.64	4.12	0.29	1.000
9	80/20	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.31	20.80	5.98	0.988
20	80/20	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	14.64	20.54	6.58	0.988
10	80/20	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	16.57	25.07	7.44	0.983
18	80/20	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	20.23	27.61	9.09	0.979
19	80/20	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	26.26	37.27	11.79	0.961
11	80/20	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	26.93	38.72	12.10	0.958
1	80/20	Ingenuo (mes anterior)	-	44.15	66.71	19.83	0.876
0	80/20	Pronóstico actual (units_expected)	-	1042.04	1093.44	467.95	-32.190

In [21]:

```
# Tabla resumen: el menor WAPE (%) de cada modelo en cada partición
resumen = tabla_final.pivot_table(index='Modelo', columns='Partición', values='WAPE (%)',
aggfunc='min')
resumen = resumen[['80/20', '70/30', '60/40']].sort_values('80/20')
resumen
```

Out[21]:

Partición	80/20	70/30	60/40
Modelo			
Ingenuo estacional (mismo mes del año anterior)	0.29	0.31	0.30
Random Forest	5.98	6.07	6.12
XGBoost	6.58	6.97	7.05
Ingenuo (mes anterior)	19.83	18.65	18.17
Pronóstico actual (units_expected)	467.95	471.23	483.00

In [22]:
```
# Mejor configuración de cada modelo en la partición 80/20
# (se ordena por WAPE y se deja solo la primera fila de cada modelo)
mejores = tabla_final[tabla_final['Partición'] == '80/20'].sort_values('WAPE (%)')
mejores = mejores.drop_duplicates(subset='Modelo')
mejores[['Modelo', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
```

Out[22]:

	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
2	Ingenuo estacional (mismo mes del año anterior)	-	0.64	4.12	0.29	1.000
9	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.31	20.80	5.98	0.988
20	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	14.64	20.54	6.58	0.988
1	Ingenuo (mes anterior)	-	44.15	66.71	19.83	0.876
0	Pronóstico actual (units_expected)	-	1042.04	1093.44	467.95	-32.190

10.1 Comprobación de los hiperparámetros con validación temporal

En las tablas anteriores (análisis exploratorio) se vio el error de todas las configuraciones en los meses de prueba, así que elegir la mejor con esas tablas da un resultado **optimista**. Para comprobar la elección sin depender de esos meses:

1. Dentro del periodo de entrenamiento se separa una **validación**: se entrena hasta abril 2025 y se evalúa con mayo–agosto 2025.
2. Se elige **automáticamente** la configuración con menor error en validación para cada modelo.
3. Esas configuraciones son las que se usan en las secciones 11 a 13.

In [23]:
```
entrenamiento_val = datos['fecha'] < '2025-05-01'
validacion = (datos['fecha'] >= '2025-05-01') & (datos['fecha'] < '2025-09-01')

tabla_validacion = []

for hiperparametros, modelo in opciones_rf.items():
    modelo.fit(X[entrenamiento_val], y[entrenamiento_val])
    fila = evaluar(y[validacion], modelo.predict(X[validacion]))
    fila['Modelo'] = 'Random Forest'
    fila['Hiperparámetros'] = hiperparametros
    tabla_validacion.append(fila)

for hiperparametros, modelo in opciones_xgb.items():
    modelo.fit(X[entrenamiento_val], y[entrenamiento_val])
    fila = evaluar(y[validacion], modelo.predict(X[validacion]))
    fila['Modelo'] = 'XGBoost'
    fila['Hiperparámetros'] = hiperparametros
    tabla_validacion.append(fila)

tabla_validacion = pd.DataFrame(tabla_validacion).sort_values('WAPE (%)')

# La mejor configuración de cada modelo es la de menor WAPE en validación
mejor_hiper_rf = tabla_validacion[tabla_validacion['Modelo'] == 'Random Forest']
['Hiperparámetros'].iloc[0]
mejor_hiper_xgb = tabla_validacion[tabla_validacion['Modelo'] == 'XGBoost']
```

```
['Hiperparámetros'].iloc[0]
print('Configuración elegida para Random Forest:', mejor_hiper_rf)
print('Configuración elegida para XGBoost:', mejor_hiper_xgb)

print('Error en VALIDACIÓN (mayo–agosto 2025):')
tabla_validacion[['Modelo', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
```

```
Configuración elegida para Random Forest: n_estimators=100, max_depth=None, min_samples_leaf=1
Configuración elegida para XGBoost: n_estimators=800, learning_rate=0.03, max_depth=8
Error en VALIDACIÓN (mayo–agosto 2025):
```

Out[23]:

	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
0	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.20	20.67	6.28	0.986
5	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	16.64	22.91	7.91	0.983
1	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	18.59	26.92	8.84	0.976
3	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	21.08	28.98	10.02	0.973
4	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	25.94	37.02	12.33	0.955
2	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	27.72	40.27	13.18	0.947

Resultado: la validación temporal eligió **Random Forest con 100 árboles sin límite de profundidad** y **XGBoost con 800 árboles, `learning_rate` = 0.03 y `max_depth` = 8**, las mismas configuraciones identificadas en el análisis exploratorio. Como los meses de prueba (septiembre–diciembre 2025) ya se habían consultado en las secciones 8–10, **falta una evaluación independiente con datos nuevos**.

11. Resultados de los mejores modelos

Se entrenan las configuraciones elegidas en validación con todos los datos hasta agosto 2025 y se evalúan en septiembre–diciembre 2025 (partición 80/20) para visualizar sus resultados.

In [24]:

```
corte = '2025-09-01'
entrenamiento = datos['fecha'] < corte
prueba = datos['fecha'] >= corte

# Tomamos de los diccionarios los modelos elegidos en la validación y los entrenamos
mejor_rf = opciones_rf[mejor_hiper_rf]
mejor_rf.fit(X[entrenamiento], y[entrenamiento])

mejor_xgb = opciones_xgb[mejor_hiper_xgb]
mejor_xgb.fit(X[entrenamiento], y[entrenamiento])

# Guardamos los pronósticos en una tabla
resultado = datos.loc[prueba, ['fecha', 'region', 'units_sold', 'units_expected']].copy()
resultado['pronostico_rf'] = mejor_rf.predict(X[prueba])
resultado['pronostico_xgb'] = mejor_xgb.predict(X[prueba])

print('Resultado en la prueba (septiembre–diciembre 2025):')
print('Random Forest:', evaluar(resultado['units_sold'], resultado['pronostico_rf']))
print('XGBoost:      ', evaluar(resultado['units_sold'], resultado['pronostico_xgb']))

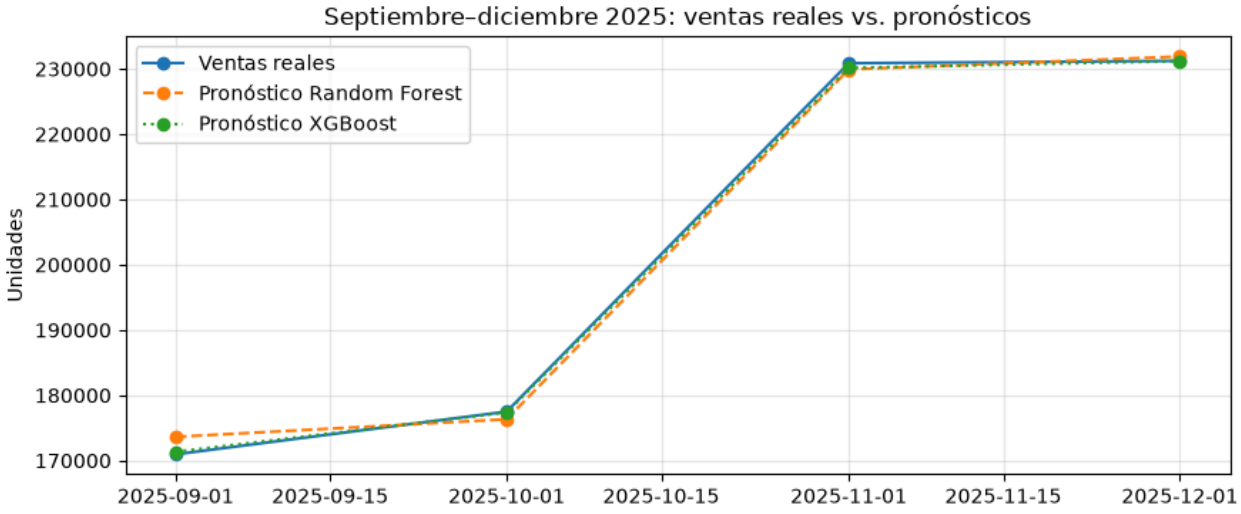
# Total por mes: ventas reales vs. pronósticos de los dos modelos
total_mes = resultado.groupby('fecha')[['units_sold', 'pronostico_rf', 'pronostico_xgb',
'units_expected']].sum()

plt.figure(figsize=(10, 4))
plt.plot(total_mes.index, total_mes['units_sold'], marker='o', label='Ventas reales')
plt.plot(total_mes.index, total_mes['pronostico_rf'], marker='o', linestyle='--',
label='Pronóstico Random Forest')
plt.plot(total_mes.index, total_mes['pronostico_xgb'], marker='o', linestyle=':',
label='Pronóstico XGBoost')
plt.title('Septiembre–diciembre 2025: ventas reales vs. pronósticos')
plt.ylabel('Unidades')
plt.legend()
```

```
plt.grid(alpha=0.3)
plt.show()

# El pronóstico actual no se grafica porque es ~6 veces mayor y aplastaría la escala
total_mes.round(0)
```

```
Resultado en la prueba (septiembre–diciembre 2025):
Random Forest: {'MAE': 13.31, 'RMSE': 20.8, 'WAPE (%)': 5.98, 'R2': 0.988}
XGBoost:       {'MAE': 14.64, 'RMSE': 20.54, 'WAPE (%)': 6.58, 'R2': 0.988}
```



Out[24]:

fecha	units_sold	pronostico_rf	pronostico_xgb	units_expected
2025-09-01	170951	173630.0	171342.0	1156597
2025-10-01	177498	176332.0	177364.0	1145364
2025-11-01	230877	229923.0	230154.0	1150628
2025-12-01	231237	231907.0	231206.0	1151011

Interpretación: los dos modelos siguen muy de cerca las ventas reales, incluida la subida de noviembre y diciembre. En el total de cada mes, Random Forest se desvía menos de 2 % (la mayor diferencia es septiembre, +1.6 %), mientras que el pronóstico actual espera ~1.15 millones de unidades al mes contra ~170–230 mil que se venden.

In [25]:

```
# Función que hace las 3 gráficas de errores de un modelo
def graficar_residuales(nombre, pronostico):
    residual = resultado['units_sold'] - pronostico      # error = real - estimado

    fig, ax = plt.subplots(1, 3, figsize=(15, 4))

    # 1) Real vs. estimado: si el modelo fuera perfecto, todos los puntos caerían en la línea
roja
    ax[0].scatter(resultado['units_sold'], pronostico, s=5, alpha=0.4)
    maximo = resultado['units_sold'].max()
    ax[0].plot([0, maximo], [0, maximo], color='red')
    ax[0].set_title('Real vs. estimado (' + nombre + ')')
    ax[0].set_xlabel('Unidades reales')
    ax[0].set_ylabel('Unidades estimadas')

    # 2) Distribución de los residuales: deberían estar centrados en 0
    ax[1].hist(residual, bins=50)
    ax[1].axvline(0, color='red')
    ax[1].set_title('Distribución de los residuales (' + nombre + ')')
    ax[1].set_xlabel('Real - estimado (unidades)')

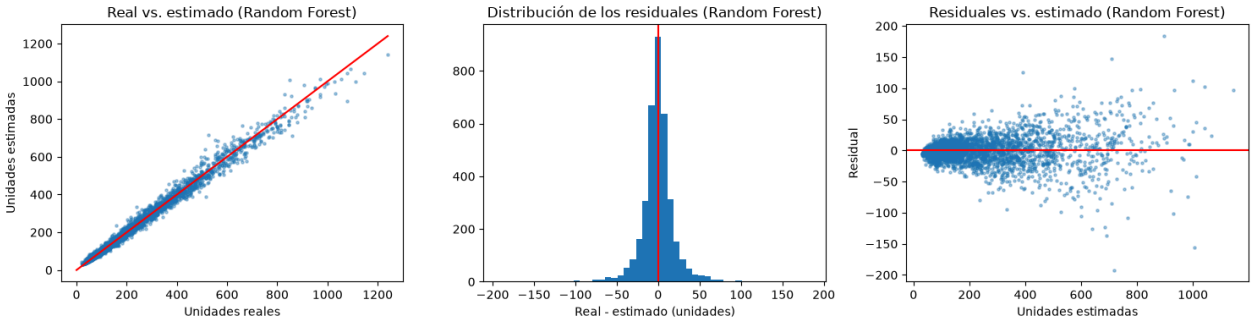
    # 3) Residuales vs. estimado: no debería haber un patrón
    ax[2].scatter(pronostico, residual, s=5, alpha=0.4)
    ax[2].axhline(0, color='red')
```

```
    ax[2].set_title('Residuales vs. estimado (' + nombre + ')')
    ax[2].set_xlabel('Unidades estimadas')
    ax[2].set_ylabel('Residual')

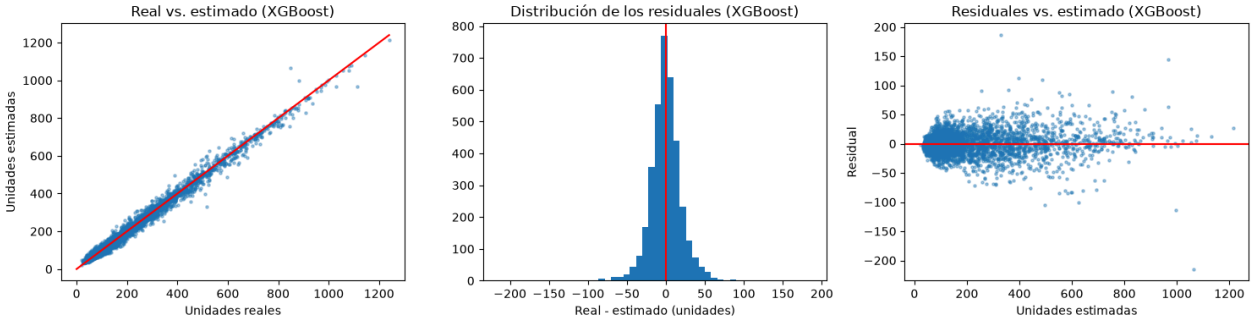
    plt.tight_layout()
    plt.show()

    print(nombre, '-> residual promedio:', round(residual.mean(), 2), 'unidades')
    print('El 90% de los errores está entre', round(residual.quantile(0.05), 1), 'y',
round(residual.quantile(0.95), 1), 'unidades')

graficar_residuales('Random Forest', resultado['pronostico_rf'])
graficar_residuales('XGBoost', resultado['pronostico_xgb'])
```




```
Random Forest -> residual promedio: -0.34 unidades
El 90% de los errores está entre -29.9 y 29.9 unidades
```




```
XGBoost -> residual promedio: 0.14 unidades
El 90% de los errores está entre -29.9 y 33.0 unidades
```

Interpretación:

- **Real vs. estimado:** en los dos modelos los puntos quedan pegados a la línea roja, es decir, los pronósticos se parecen mucho a las ventas reales en productos de venta baja y alta.
- **Distribución de residuales:** está centrada en 0 (promedio de −0.34 unidades en Random Forest y 0.14 en XGBoost) y el 90 % de los errores queda entre −30 y +33 unidades. Los modelos no tienden a sobrestimar ni a subestimar.
- **Residuales vs. estimado:** no se ve un patrón claro; los errores en unidades se abren en los productos que más venden, lo cual es normal porque un mismo porcentaje de error equivale a más unidades (en porcentaje, el error de esos productos es incluso menor).

In [26]:
```
# Error de los dos modelos por región
resultado['error_rf'] = np.abs(resultado['units_sold'] - resultado['pronostico_rf'])
resultado['error_xgb'] = np.abs(resultado['units_sold'] - resultado['pronostico_xgb'])

sumas = resultado.groupby('region')[['units_sold', 'error_rf', 'error_xgb']].sum()
sumas['WAPE Random Forest (%)'] = (sumas['error_rf'] / sumas['units_sold'] * 100).round(2)
sumas['WAPE XGBoost (%)'] = (sumas['error_xgb'] / sumas['units_sold'] * 100).round(2)

sumas[['WAPE Random Forest (%)', 'WAPE XGBoost (%)']].sort_values('WAPE Random Forest (%)')
```

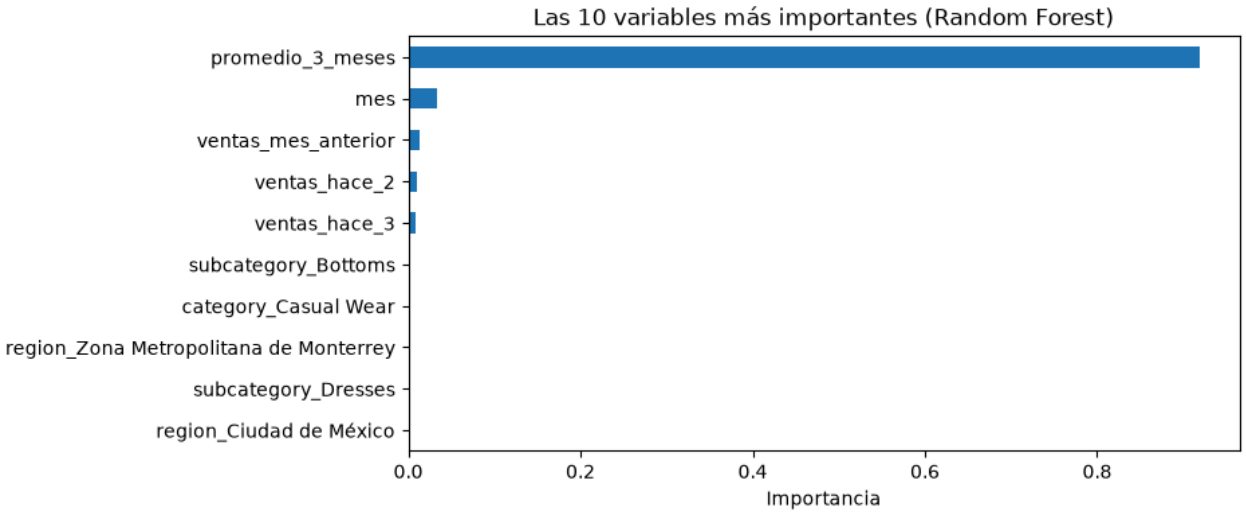
Out[26]:

region	WAPE Random Forest (%)	WAPE XGBoost (%)
Ciudad de México	5.21	3.64
Zona Metropolitana de Monterrey	5.78	5.64
Zona Metropolitana de Guadalajara	5.83	7.08
Bajío	6.54	9.53
Noroeste	7.27	11.62
Sur	7.82	11.53
Sureste	8.15	12.73

Interpretación: Random Forest tiene un error parejo en todas las regiones (de 5.2 % en CDMX a 8.2 % en el Sureste). XGBoost es mejor en CDMX y Monterrey, pero falla más en las regiones de menor venta (hasta 12.7 % en el Sureste). Por eso Random Forest es más confiable para planear el inventario de todas las regiones.

In [27]:
```
# ¿Qué variables usa más el modelo? (segundo método de selección de variables)
importancia = pd.Series(mejor_rf.feature_importances_,
index=X.columns).sort_values(ascending=False).head(10)

plt.figure(figsize=(8, 4))
importancia.sort_values().plot(kind='barh')
plt.title('Las 10 variables más importantes (Random Forest)')
plt.xlabel('Importancia')
plt.show()
```



Interpretación: el **promedio de ventas de los últimos 3 meses** es por mucho la variable más importante (~0.92 de la importancia total), seguido del **mes** (~0.03), que captura la temporada. Región y categoría pesan poco por separado, probablemente porque su efecto ya está reflejado en el nivel de ventas reciente de cada serie. Esto confirma la selección de variables de la sección 3.

12. Impacto del preprocesamiento

Para medir qué tanto ayudó la preparación de los datos, se entrenan los dos modelos (partición 80/20, mejores hiperparámetros) con **4 grupos de variables**:

1. **Básicas:** región, categoría, subcategoría y mes (codificadas con One-Hot).
2. **Básicas + precio** (el precio como identificador del producto).
3. **Básicas + ventas pasadas** (las variables creadas en el preprocesamiento): **modelo final**.
4. **Básicas + ventas pasadas + precio** (prueba de robustez: ¿cuánto aporta el precio?).

In [28]:
```
from sklearn.base import clone   # clone() hace una copia del modelo SIN entrenar (con los mismos hiperparámetros)

basicas = ['region', 'category', 'subcategory', 'mes']
rezagos = ['ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3', 'promedio_3_meses']

grupos = {
    '1. Básicas': basicas,
    '2. Básicas + precio': basicas + ['static_price'],
    '3. Básicas + ventas pasadas (modelo final)': basicas + rezagos,
    '4. Básicas + ventas pasadas + precio': basicas + rezagos + ['static_price'],
}

comparacion = []
for nombre_modelo, modelo_elegido in [('Random Forest', mejor_rf), ('XGBoost', mejor_xgb)]:
    for nombre_grupo, columnas in grupos.items():
        X_grupo = pd.get_dummies(datos[columnas], columns=['region', 'category', 'subcategory'], dtype=int)

        modelo = clone(modelo_elegido)
        modelo.fit(X_grupo[entrenamiento], y[entrenamiento])

        fila = evaluar(y[prueba], modelo.predict(X_grupo[prueba]))
        fila['Modelo'] = nombre_modelo
        fila['Variables'] = nombre_grupo
        comparacion.append(fila)

pd.DataFrame(comparacion)[['Modelo', 'Variables', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
```

Out[28]:

	Modelo	Variables	MAE	RMSE	WAPE (%)	R2
0	Random Forest	1. Básicas	50.43	78.20	22.65	0.830
1	Random Forest	2. Básicas + precio	14.34	22.57	6.44	0.986
2	Random Forest	3. Básicas + ventas pasadas (modelo final)	13.31	20.80	5.98	0.988
3	Random Forest	4. Básicas + ventas pasadas + precio	13.08	20.29	5.87	0.989
4	XGBoost	1. Básicas	50.36	78.16	22.62	0.830
5	XGBoost	2. Básicas + precio	15.63	21.89	7.02	0.987
6	XGBoost	3. Básicas + ventas pasadas (modelo final)	14.64	20.54	6.58	0.988
7	XGBoost	4. Básicas + ventas pasadas + precio	13.23	18.73	5.94	0.990

Interpretación:

- Con solo las variables **básicas** el error es alto: el modelo sabe la región, la categoría y el mes, pero no cuánto vende cada producto.
- Con el **precio** el error baja mucho, probablemente porque el modelo lo usa para **reconocer el producto** (cada producto tiene un precio único) y "recordar" lo que vendió en 2024, que se repite en 2025.
- Con las **ventas pasadas** (creadas en el preprocesamiento) el error baja casi igual **sin identificar el producto**: el modelo aprende del nivel de ventas reciente de cada serie.
- **Prueba de robustez:** agregar el precio a las ventas pasadas casi no cambia el error. Es decir, el modelo final no depende del precio, y por eso se excluyó para reducir esa dependencia. Que esto lo haga más robusto ante cambios de precio es algo pendiente de validar, y el modelo **no sirve para productos nuevos**, porque necesita 3 meses de ventas previas.

13. Pronóstico de varios meses (recursivo)

Hasta aquí, para pronosticar cada mes de prueba el modelo usó las **ventas reales** del mes anterior (pronóstico a **un mes**). En la vida real, si DanuStore quiere planear septiembre–diciembre desde agosto, todavía no conoce las ventas de septiembre, octubre ni noviembre.

Por eso se hace un **pronóstico recursivo**: se pronostica septiembre; ese pronóstico se usa como "venta del mes anterior" para pronosticar octubre, y así sucesivamente. Los errores se van acumulando, así que este es el **error realista para planear varios meses**.

In [29]:
```
# Función que calcula las ventas pasadas (igual que en la sección 3), pero sobre la columna que le digamos
def calcular_rezagos(tabla, columna):
    grupo = tabla.groupby(['product_id', 'region'])[columna]
    tabla['ventas_mes_anterior'] = grupo.shift(1)
    tabla['ventas_hace_2'] = grupo.shift(2)
    tabla['ventas_hace_3'] = grupo.shift(3)
    tabla['promedio_3_meses'] = (tabla['ventas_mes_anterior'] + tabla['ventas_hace_2'] + tabla['ventas_hace_3']) / 3
    return tabla

meses_prueba = ['2025-09-01', '2025-10-01', '2025-11-01', '2025-12-01']
recursivo = []

for nombre_modelo, modelo in [('Random Forest', mejor_rf), ('XGBoost', mejor_xgb)]:

    # 1) Copiamos los datos y "borramos" las ventas desde septiembre 2025 (como si aún no las conociéramos)
    historia = df.copy()
    historia['ventas_simuladas'] = historia['units_sold']
    historia.loc[historia['fecha'] >= '2025-09-01', 'ventas_simuladas'] = np.nan

    # 2) Pronosticamos un mes a la vez y guardamos el pronóstico como si fuera la venta de ese mes
    for mes in meses_prueba:
        historia = calcular_rezagos(historia, 'ventas_simuladas')
        X_historia = pd.get_dummies(historia[variables], columns=['region', 'category', 'subcategory'], dtype=int)

        filas_del_mes = historia['fecha'] == mes
        historia.loc[filas_del_mes, 'ventas_simuladas'] = modelo.predict(X_historia[filas_del_mes])

    # 3) Comparamos los pronósticos contra las ventas reales, mes por mes
    numero_de_mes = 1
    for mes in meses_prueba:
        filas_del_mes = historia['fecha'] == mes
        fila = evaluar(historia.loc[filas_del_mes, 'units_sold'], historia.loc[filas_del_mes, 'ventas_simuladas'])
        fila['Modelo'] = nombre_modelo
        fila['Mes'] = mes[:7]
        fila['Meses adelante'] = numero_de_mes
        recursivo.append(fila)
        numero_de_mes = numero_de_mes + 1

    # 4) Y el bloque completo septiembre–diciembre
    filas_prueba = historia['fecha'] >= '2025-09-01'
    fila = evaluar(historia.loc[filas_prueba, 'units_sold'], historia.loc[filas_prueba, 'ventas_simuladas'])
    fila['Modelo'] = nombre_modelo
    fila['Mes'] = 'Bloque sep–dic'
    fila['Meses adelante'] = '1 a 4'
    recursivo.append(fila)

tabla_recursiva = pd.DataFrame(recursivo)[['Modelo', 'Mes', 'Meses adelante', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
tabla_recursiva
```

Out[29]:

	Modelo	Mes	Meses adelante	MAE	RMSE	WAPE (%)	R2
0	Random Forest	2025-09	1	10.95	16.61	5.83	0.988
1	Random Forest	2025-10	2	18.38	27.97	9.42	0.971
2	Random Forest	2025-11	3	27.76	40.78	10.94	0.962
3	Random Forest	2025-12	4	31.15	47.01	12.26	0.951
4	Random Forest	Bloque sep–dic	1 a 4	22.06	35.11	9.91	0.966
5	XGBoost	2025-09	1	13.68	18.63	7.28	0.985
6	XGBoost	2025-10	2	18.57	26.01	9.52	0.975
7	XGBoost	2025-11	3	27.91	39.40	11.00	0.965
8	XGBoost	2025-12	4	30.57	45.18	12.03	0.955
9	XGBoost	Bloque sep–dic	1 a 4	22.68	33.97	10.19	0.968

In [30]:

```
# Comparación: error a un mes vs. error recursivo (septiembre–diciembre 2025)
bloque = tabla_recursiva[tabla_recursiva['Mes'] == 'Bloque sep–dic']

comparacion_horizonte = pd.DataFrame({
    'Modelo': ['Random Forest', 'XGBoost', 'Pronóstico actual (units_expected)'],
    'A un mes (ventas reales)': [evaluar(resultado['units_sold'], resultado['pronostico_rf'])
['WAPE (%)'],
                                 evaluar(resultado['units_sold'], resultado['pronostico_xgb'])
['WAPE (%)'],
                                 evaluar(resultado['units_sold'], resultado['units_expected'])
['WAPE (%)']],
    'Recursivo (bloque sep–dic)': [bloque['WAPE (%)'].iloc[0],
                                   bloque['WAPE (%)'].iloc[1],
                                   evaluar(resultado['units_sold'],
resultado['units_expected'])['WAPE (%)']],
})
print('WAPE (%) en septiembre–diciembre 2025:')
comparacion_horizonte
```

```
WAPE (%) en septiembre–diciembre 2025:
```

Out[30]:

	Modelo	A un mes (ventas reales)	Recursivo (bloque sep-dic)
0	Random Forest	5.98	9.91
1	XGBoost	6.58	10.19
2	Pronóstico actual (units_expected)	467.95	467.95

Interpretación: al pronosticar varios meses con sus propios pronósticos, el error **crece mes a mes** porque los errores se acumulan. El error **del bloque completo** septiembre–diciembre es el que se compara en la tabla; el error **a cuatro meses de horizonte** (solo diciembre) es mayor, y aparece en la tabla anterior. Aun así, los dos son mucho menores que el error del pronóstico actual de DanuStore.

14. Conclusiones

Resultados por partición (WAPE a un mes):

Partición	Ingenuo estacional (año anterior)	Random Forest	XGBoost	Ingenuo (mes anterior)	Pronóstico actual
80/20	0.29 %	**5.98 %**	6.58 %	19.8 %	468 %
70/30	0.31 %	**6.07 %**	6.97 %	18.7 %	471 %
60/40	0.30 %	**6.12 %**	7.05 %	18.2 %	483 %

¿Qué modelo y qué división funcionaron mejor?

- **Entre los modelos de ML evaluados, el mejor es Random Forest** (100 árboles, sin límite de profundidad). Tiene el menor WAPE en las tres particiones, y la validación temporal (mayo–agosto 2025) confirmó las configuraciones identificadas en el análisis exploratorio. Como el periodo septiembre–diciembre ya había sido consultado, **falta una evaluación independiente con**

datos nuevos. En septiembre–diciembre 2025 obtuvo un WAPE de 5.98 %, un MAE de 13.31 unidades y un R^2 de 0.988.

- **XGBoost** quedó cerca (6.58 %, mismo R^2 y RMSE ligeramente menor, 20.54 contra 20.80), pero su error es menos parejo entre regiones: Random Forest va de 5.2 % a 8.2 %, y XGBoost de 3.6 % a 12.7 %.
- **Particiones:** los resultados son muy parecidos en las tres (5.98 % a 6.12 % para Random Forest). Como los periodos de prueba son distintos y se enciman, **no se puede afirmar que una división sea mejor**; lo que muestran es que el modelo es **estable**, incluso entrenando con solo 13 meses.
- **Ambos modelos le ganan por mucho al pronóstico actual de DanuStore** (~470 %) y a repetir el mes pasado (~19 %).
- **El ingenuo estacional (repetir el mismo mes del año anterior) obtuvo el menor error entre los métodos evaluados (~0.3 %).** Esto se debe a que en esta base **las ventas de 2025 son casi una copia de las de 2024** (76.6 % de los registros son idénticos). Los modelos de ML se construyeron sin esa información como decisión experimental, para que dependan del nivel de ventas reciente, la región y la temporada; si eso los hace más útiles cuando las ventas no se repiten queda **pendiente de validar** con datos nuevos.
- **Pronóstico de varios meses:** si se pronostica septiembre–diciembre desde agosto, usando los propios pronósticos como entrada, el error de Random Forest sube mes a mes: 5.8 % a un mes (septiembre), 9.4 % a dos, 10.9 % a tres y **12.3 % a cuatro meses** (diciembre). Para el **bloque completo septiembre–diciembre** el error es de **9.9 %**.
- **Residuales:** en los dos modelos están centrados en 0 y el 90 % de los errores está entre −30 y +33 unidades, sin un patrón visible.

¿Qué impacto tuvo el preprocesamiento?

- **Crear las ventas pasadas** fue lo más importante. Con solo región, categoría, subcategoría y mes el error es de **22.6 %**; con las ventas pasadas baja a **6.0 %** en Random Forest y 6.6 % en XGBoost.
- **Excluir `static_price`:** como cada producto tiene un precio único, el precio funcionaba como identificador del producto. La prueba de robustez muestra que quitarlo casi no cambia el error (5.87 % con precio contra 5.98 % sin él), así que el modelo no depende de él. Se excluyó para reducir esa dependencia; su efecto ante cambios de precio queda pendiente de validar.
- **Excluir las variables con fuga** (Ventas_Acumuladas, Venta_Promedio_Diaria, Cumplimiento, etc.) evita un modelo "perfecto" pero inútil en la vida real.
- **El One-Hot Encoding** permitió usar región, categoría y subcategoría. **La normalización no fue necesaria** porque los modelos de árboles no dependen de la escala.

¿Qué impacto tuvo el ajuste de hiperparámetros? Se compararon **configuraciones completas** (en cada una cambian varios hiperparámetros a la vez), así que no se puede atribuir la diferencia a un solo parámetro. Lo que sí se observa:

- **Random Forest:** las configuraciones con árboles más limitados (menor `max_depth`, mayor `min_samples_leaf`) tuvieron más error: 5.98 % sin límite, 7.44 % con `max_depth` = 15 y 12.10 % con `max_depth` = 8 (partición 80/20).
- **XGBoost:** la configuración con árboles poco profundos (`max_depth` = 4) tuvo 11.79 %, y la de 800 árboles, `learning_rate` = 0.03 y `max_depth` = 8 bajó a 6.58 %.
- En los dos casos, las configuraciones más flexibles funcionaron mejor, lo cual tiene sentido porque necesitan distinguir 910 combinaciones de producto y región.

Beneficio para DanuStore: con un pronóstico basado en las ventas reales recientes, la región y la temporada, puede planear su stock según lo que realmente se va a vender, en lugar de un pronóstico plano e inflado, y así reducir el sobreinventario (según el análisis de la investigación 5.1, hoy el stock alcanza para ~208 días de venta real en lugar de los ~34 planeados).

Limitantes:

1. **Las ventas de 2025 repiten casi exactamente las de 2024.** Por eso repetir el año anterior es casi perfecto y los errores de los modelos son **optimistas**. Hay que confirmar con DanuStore si estos datos son reales y validar el modelo con datos nuevos antes de usarlo.
2. Las ventas son solo de clientes registrados.
3. El error crece con el horizonte: ~6 % a un mes y ~12 % a cuatro meses (9.9 % para el bloque de cuatro meses). Lo recomendable es reentrenar y pronosticar cada mes con las ventas reales más recientes.
4. El modelo necesita **3 meses de ventas previas** de cada producto y región, así que no sirve para productos nuevos sin historial.
5. Los meses de prueba (septiembre–diciembre 2025) se consultaron durante el análisis exploratorio, así que el error reportado puede ser optimista; la validación confirmó la elección, pero se necesita una evaluación con datos nuevos.