TI3002C – Etapa 5.1: Código ML

Equipo 6 – Nexxus Consulting Nombre: Jaime Hernández González **Matrícula:** A00840312

Problemática (regresión): pronosticar las **unidades vendidas (`units_sold`)** de cada producto, en cada región y en cada mes, para que DanuStore planee su inventario con un pronóstico más preciso que el que usa hoy (`units_expected`).

Modelos: Random Forest y XGBoost (los dos propuestos en la investigación de la Etapa 5.1).

1. Librerías

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.ensemble import RandomForestRegressor
from xgboost import XGBRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

pd.set_option('display.max_colwidth', None)   # para ver los hiperparámetros completos en las tablas
```

2. Importar datos

Se usa la base **mensual (Nivel Macro)**: 130 productos × 7 regiones × 24 meses (2024–2025).

In [2]:
```
# Si usas Google Drive, monta tu Drive y cambia la ruta:
# from google.colab import drive
# drive.mount('/content/drive')
# df = pd.read_csv('/content/drive/MyDrive/data_DanuStore_Equipo6_Mensual.csv')

df = pd.read_csv('data_DanuStore_Equipo6_Mensual.csv')
print(df.shape)
df.head()
```

```
(21840, 20)
```

Out[2]:

	month	year	product_id	region	units_expected	stock	percentage	units_sold	sales_amount	product_name
0	March	2025	39	Bajío	1057	1735	164.14	107	4045.32	Shirts Product 39
1	October	2025	46	Ciudad de México	1983	3215	162.13	671	49978.14	Pants Product 46
2	May	2025	113	Ciudad de México	2549	4030	158.10	693	52325.53	Boots Product 113
3	February	2025	75	Ciudad de México	1388	2192	157.93	355	23911.75	Jewelry Product 75
4	October	2025	84	Ciudad de México	1458	2298	157.61	467	18204.74	Hats Product 84

2.0 Exploración inicial

Revisamos el tamaño de la base, los tipos de datos, si hay valores nulos o registros duplicados, y las estadísticas básicas de la variable objetivo.

In [3]:
```
print('Filas y columnas:', df.shape)
print('Valores nulos en toda la base:', df.isnull().sum().sum())
print('Registros duplicados:', df.duplicated().sum())
print('Productos:', df['product_id'].nunique(), '| Regiones:', df['region'].nunique(), '|
Categorías:', df['category'].nunique())
df.dtypes
```

```
Filas y columnas: (21840, 20)
Valores nulos en toda la base: 0
Registros duplicados: 0
Productos: 130 | Regiones: 7 | Categorías: 4
```

Out[3]:
```
month                              str
year                             int64
product_id                       int64
region                             str
units_expected                   int64
stock                            int64
percentage                     float64
units_sold                       int64
sales_amount                   float64
product_name                       str
category                           str
subcategory                        str
static_price                   float64
inventory_key                      str
Ventas_Acumuladas_Mensual        int64
Stock_Restante_Mensual           int64
Cumplimiento_Venta_Esperada    float64
Product_Repeat_Purchase_Rate   float64
Venta_Promedio_Diaria          float64
Dias_Cobertura_Inventario      float64
dtype: object
```

In [4]:
```
df[['units_sold', 'units_expected', 'stock', 'static_price']].describe().round(2)
```

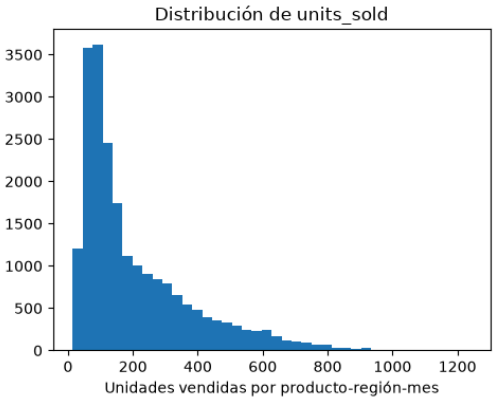
Out[4]:

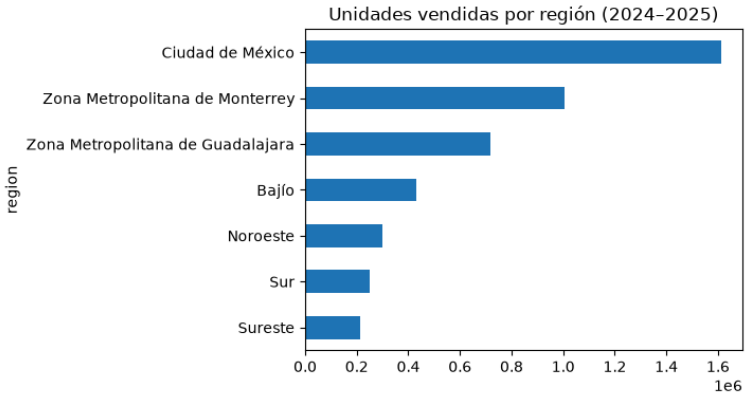
	units_sold	units_expected	stock	static_price
count	21840.00	21840.00	21840.00	21840.00
mean	207.55	1222.49	1358.55	83.64
std	175.59	434.38	566.11	44.36
min	15.00	323.00	120.00	21.99
25%	81.00	888.75	930.00	48.67
50%	138.50	1192.00	1279.00	77.18
75%	286.00	1507.00	1703.00	104.50
max	1240.00	3111.00	4732.00	231.68

In [5]:
```
fig, ax = plt.subplots(1, 2, figsize=(12, 4))

ax[0].hist(df['units_sold'], bins=40)
ax[0].set_title('Distribución de units_sold')
ax[0].set_xlabel('Unidades vendidas por producto-región-mes')

df.groupby('region')['units_sold'].sum().sort_values().plot(kind='barh', ax=ax[1])
ax[1].set_title('Unidades vendidas por región (2024–2025)')
plt.tight_layout()
plt.show()
```





Interpretación: la base no tiene nulos ni duplicados. `units_sold` tiene sesgo a la derecha (la mayoría de los registros vende poco y pocos venden mucho) y las ventas se concentran en CDMX, Monterrey y Guadalajara, por lo que la **región** será una variable importante.

2.1 Preparar la fecha

La columna `month` viene como texto (January, February…). La convertimos a número y creamos una fecha para poder ordenar los datos en el tiempo.

In [6]:
```
meses = {'January': 1, 'February': 2, 'March': 3, 'April': 4, 'May': 5, 'June': 6,
         'July': 7, 'August': 8, 'September': 9, 'October': 10, 'November': 11, 'December': 12}

df['mes'] = df['month'].map(meses)
df['fecha'] = pd.to_datetime(dict(year=df['year'], month=df['mes'], day=1))

# Ordenar por producto, región y fecha
df = df.sort_values(['product_id', 'region', 'fecha']).reset_index(drop=True)
df[['product_id', 'region', 'fecha', 'units_sold', 'units_expected']].head()
```

Out[6]:

	product_id	region	fecha	units_sold	units_expected
0	1	Bajío	2024-01-01	136	1398
1	1	Bajío	2024-02-01	161	1456
2	1	Bajío	2024-03-01	148	1363
3	1	Bajío	2024-04-01	161	1283
4	1	Bajío	2024-05-01	177	1367

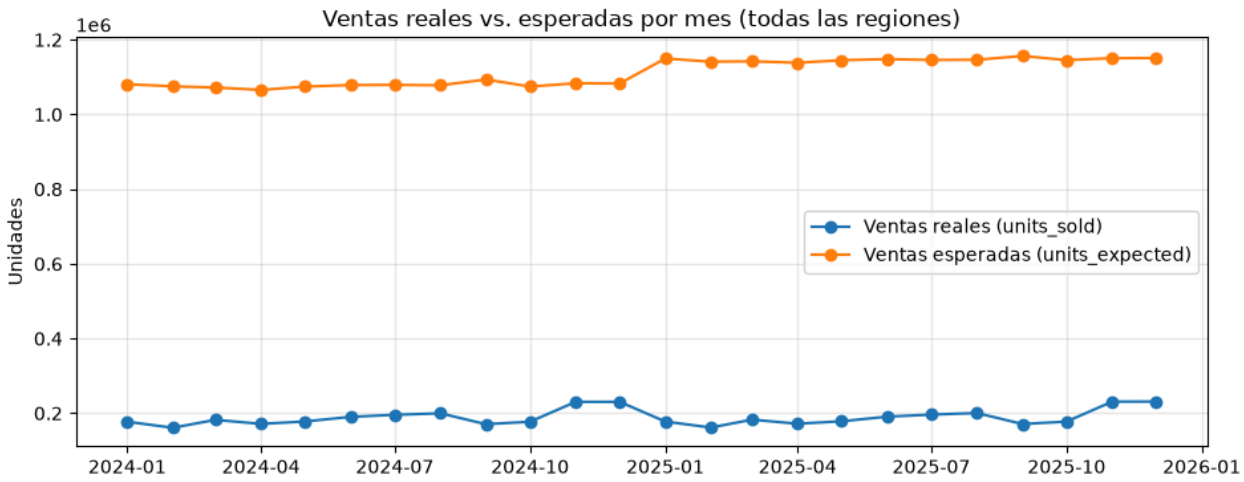
2.2 Las ventas a través del tiempo

Antes de modelar vemos cómo se comportan las ventas reales contra lo que DanuStore esperaba vender.

In [7]:
```
por_mes = df.groupby('fecha')[['units_sold', 'units_expected']].sum()

plt.figure(figsize=(11, 4))
plt.plot(por_mes.index, por_mes['units_sold'], marker='o', label='Ventas reales (units_sold)')
plt.plot(por_mes.index, por_mes['units_expected'], marker='o', label='Ventas esperadas
(units_expected)')
plt.title('Ventas reales vs. esperadas por mes (todas las regiones)')
plt.ylabel('Unidades')
plt.legend()
plt.grid(alpha=0.3)
plt.show()

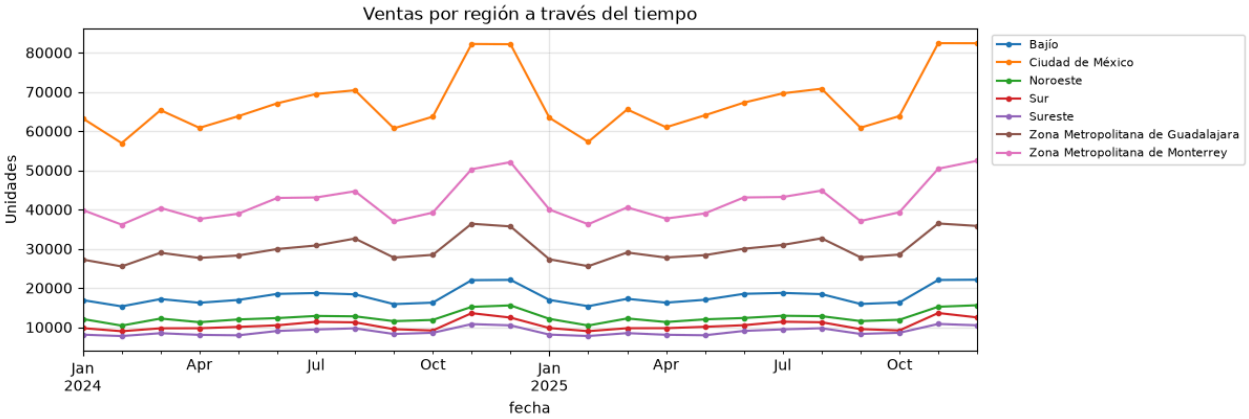
print('Se vendió el', round(por_mes['units_sold'].sum() / por_mes['units_expected'].sum() *
100, 1), '% de lo esperado')
```



Se vendió el 17.0 % de lo esperado

In [8]:
```
por_region_mes = df.groupby(['fecha', 'region'])['units_sold'].sum().unstack()

por_region_mes.plot(figsize=(11, 4), marker='.')
plt.title('Ventas por región a través del tiempo')
plt.ylabel('Unidades')
plt.legend(bbox_to_anchor=(1.01, 1), loc='upper left', fontsize=8)
plt.grid(alpha=0.3)
plt.show()
```



Interpretación: el pronóstico actual (`units_expected`) es casi plano y muy superior a las ventas reales, mientras que las ventas sí tienen picos (noviembre y diciembre) en todas las regiones, y el patrón de 2025 es igual al de 2024. Esto confirma que hace falta un modelo que aprenda el comportamiento real de las ventas.

3. Selección de variables

3.1 Universo de variables

- **Variable objetivo (y):** `units_sold` .
- **Variables candidatas:** `region` , `category` , `subcategory` , `mes` , `static_price` y las **ventas de meses anteriores** (rezagos), que creamos a continuación.

Para pronosticar el mes siguiente solo podemos usar información que **ya conocemos**. Por eso creamos:

- `ventas_mes_anterior` : ventas del mes pasado (t−1).
- `ventas_hace_2` y `ventas_hace_3` : ventas de hace 2 y 3 meses.

- `promedio_3_meses`: promedio de los 3 meses anteriores.

In [9]:
```
# Agrupamos por producto y región para que cada serie use SUS propias ventas pasadas
grupo = df.groupby(['product_id', 'region'])['units_sold']

df['ventas_mes_anterior'] = grupo.shift(1)
df['ventas_hace_2'] = grupo.shift(2)
df['ventas_hace_3'] = grupo.shift(3)
df['promedio_3_meses'] = (df['ventas_mes_anterior'] + df['ventas_hace_2'] +
df['ventas_hace_3']) / 3
df['ventas_hace_12'] = grupo.shift(12)   # mismo mes del año pasado (solo para revisarla)

df[['product_id', 'region', 'fecha', 'units_sold', 'ventas_mes_anterior',
'promedio_3_meses']].head(6)
```

Out[9]:

	product_id	region	fecha	units_sold	ventas_mes_anterior	promedio_3_meses
0	1	Bajío	2024-01-01	136	NaN	NaN
1	1	Bajío	2024-02-01	161	136.0	NaN
2	1	Bajío	2024-03-01	148	161.0	NaN
3	1	Bajío	2024-04-01	161	148.0	148.333333
4	1	Bajío	2024-05-01	177	161.0	156.666667
5	1	Bajío	2024-06-01	136	177.0	162.000000

3.2 Variables que NO se pueden usar

Estas variables se calculan **con las ventas del mismo mes** que queremos pronosticar. Si las usamos, el modelo "haría trampa" (fuga de información) porque en la vida real no las conocemos antes de que termine el mes:

Variable	Por qué se excluye
`Ventas_Acumuladas_Mensual`	Es igual a `units_sold`
`Venta_Promedio_Diaria`	Es `units_sold` ÷ días del mes
`sales_amount`	Es `units_sold` × precio
`Cumplimiento_Venta_Esperada`	Es `units_sold` ÷ `units_expected`
`Dias_Cobertura_Inventario`	Usa la venta promedio diaria
`Stock_Restante_Mensual`	Es stock − `units_sold`

`units_expected` tampoco se usa como variable: se usa como **punto de comparación** (es el pronóstico actual de la empresa).

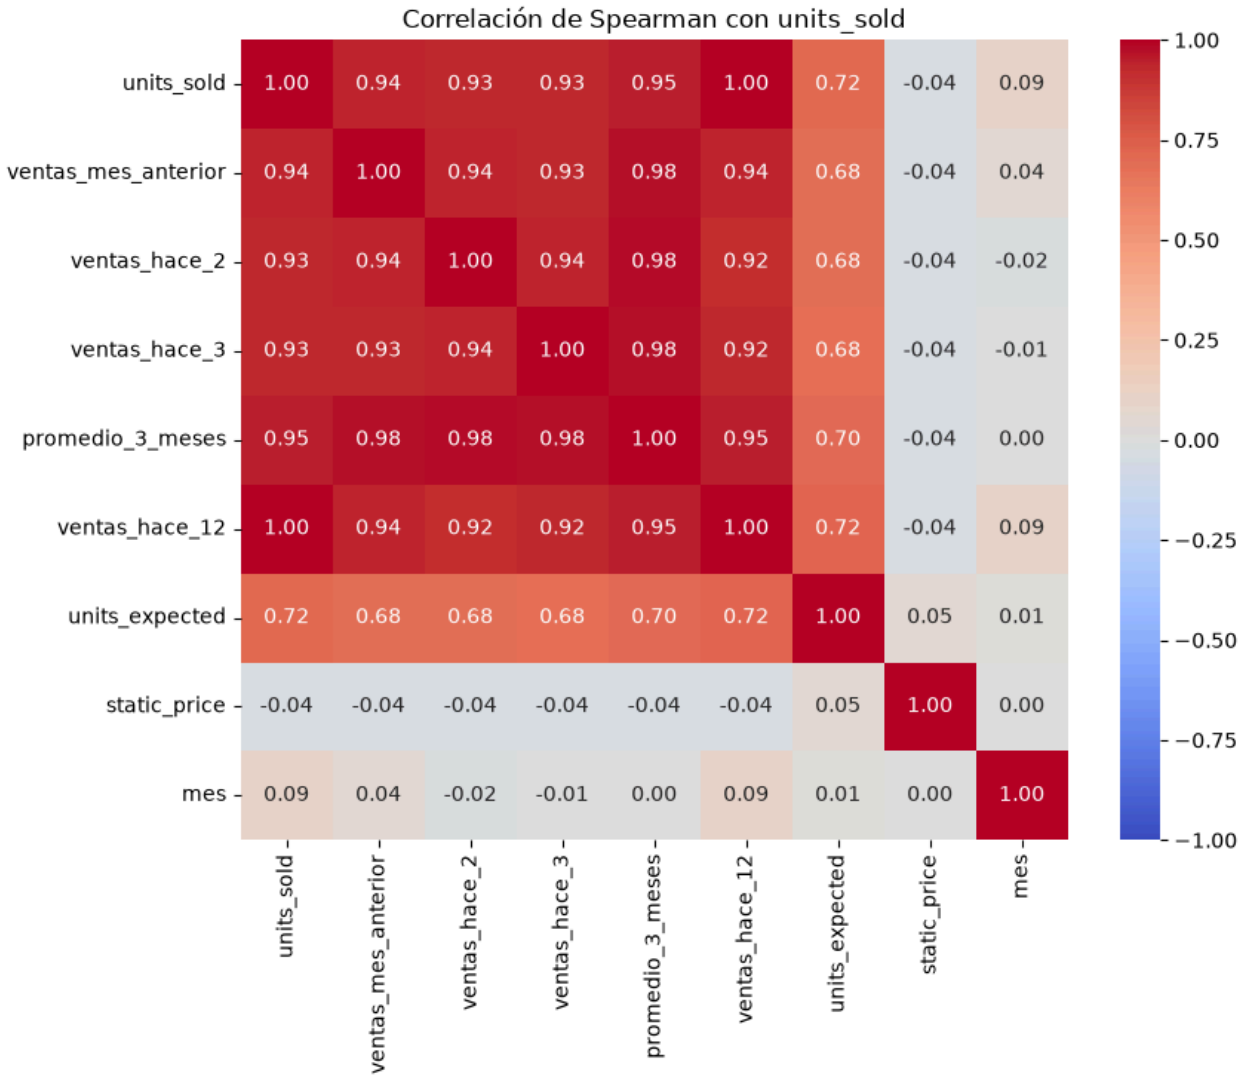
3.3 Correlaciones más importantes

In [10]:
```
variables_numericas = ['units_sold', 'ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3',
                       'promedio_3_meses', 'ventas_hace_12', 'units_expected', 'static_price',
'mes']

correlacion = df[variables_numericas].corr(method='spearman')

plt.figure(figsize=(9, 7))
sns.heatmap(correlacion, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1, vmax=1)
plt.title('Correlación de Spearman con units_sold')
plt.show()

print(correlacion['units_sold'].sort_values(ascending=False).round(3))
```




```
units_sold             1.000
ventas_hace_12         1.000
promedio_3_meses       0.950
ventas_mes_anterior    0.939
ventas_hace_3          0.927
ventas_hace_2          0.927
units_expected         0.715
mes                    0.093
static_price          -0.038
Name: units_sold, dtype: float64
```

In [11]:
```python
# ¿Las ventas de 2025 se parecen a las de 2024?
tabla = df.pivot_table(index=['product_id', 'region', 'mes'], columns='year',
values='units_sold')
iguales = (tabla[2024] == tabla[2025]).mean() * 100
print('Registros donde las ventas de 2025 son IGUALES a las de 2024:', round(iguales, 1), '%')
print('Diferencia promedio entre 2025 y 2024:', round((tabla[2025] - tabla[2024]).abs().mean(),
2), 'unidades')
```

```
Registros donde las ventas de 2025 son IGUALES a las de 2024: 76.6 %
Diferencia promedio entre 2025 y 2024: 0.61 unidades
```

Interpretación y selección:

- Las ventas de los meses anteriores (`ventas_mes_anterior` , `promedio_3_meses`) son las variables más relacionadas con `units_sold` , por eso se seleccionan.
- `units_expected` tiene una correlación menor: ordena bien qué productos venden más, pero no acierta en la cantidad.

- `static_price` y `mes` tienen correlación baja por sí solas, pero se conservan porque los árboles pueden encontrar **combinaciones** (por ejemplo, región × mes) que una correlación no detecta.
- `ventas_hace_12` **NO se usa:** su correlación es prácticamente 1 porque en la base **las ventas de 2025 repiten casi exactamente las de 2024**. Si la usáramos, el modelo solo copiaría el año anterior y no aprendería ningún patrón. Este hallazgo se reportará al socio formador como una observación sobre la calidad de los datos.

Variables seleccionadas: `region`, `category`, `subcategory`, `mes`, `static_price`, `ventas_mes_anterior`, `ventas_hace_2`, `ventas_hace_3`, `promedio_3_meses`.

4. Codificar variables categóricas

Los modelos solo entienden números. `region`, `category` y `subcategory` son texto, así que se convierten con **One-Hot Encoding** (`pd.get_dummies`): se crea una columna de 0 y 1 por cada categoría.

In [12]:
```
# Quitamos los 3 primeros meses de cada serie (no tienen ventas anteriores para calcular los rezagos)
datos = df.dropna(subset=['promedio_3_meses']).copy()

variables = ['region', 'category', 'subcategory', 'mes', 'static_price',
             'ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3', 'promedio_3_meses']

X = pd.get_dummies(datos[variables], columns=['region', 'category', 'subcategory'], dtype=int)
y = datos['units_sold']

print('Registros:', X.shape[0], '| Columnas después de codificar:', X.shape[1])
X.head()
```

```
Registros: 19110 | Columnas después de codificar: 30
```

Out[12]:

	mes	static_price	ventas_mes_anterior	ventas_hace_2	ventas_hace_3	promedio_3_meses	region_Bajío	region_Ci de M
3	4	35.16	148.0	161.0	136.0	148.333333	1	
4	5	35.16	161.0	148.0	161.0	156.666667	1	
5	6	35.16	177.0	161.0	148.0	162.000000	1	
6	7	35.16	136.0	177.0	161.0	158.000000	1	
7	8	35.16	143.0	136.0	177.0	152.000000	1	

5 rows × 30 columns

5. Normalización / estandarización

No es necesaria. Random Forest y XGBoost son modelos de **árboles de decisión**: separan los datos con reglas del tipo "¿ventas del mes anterior > 150?". Esas reglas funcionan igual si la variable está en unidades, en miles o estandarizada, así que la escala no cambia el resultado. La normalización sí sería necesaria en modelos basados en distancias o gradientes, como KNN, regresión regularizada o redes neuronales.

6. Partición de los datos (temporal)

Como queremos pronosticar el **futuro**, no se usa una partición aleatoria: se entrena con los meses más antiguos y se prueba con los más recientes. Se prueban **tres particiones** (los datos con rezagos van de abril 2024 a diciembre 2025, 21 meses):

- **80/20:** entrenar hasta agosto 2025 (17 meses) y probar con septiembre–diciembre 2025 (4 meses).
- **70/30:** entrenar hasta junio 2025 (15 meses) y probar con julio–diciembre 2025 (6 meses).
- **60/40:** entrenar hasta abril 2025 (13 meses) y probar con mayo–diciembre 2025 (8 meses).

In [13]:
```
particiones = {
    '80/20': '2025-09-01',
    '70/30': '2025-07-01',
    '60/40': '2025-05-01',
}

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    print(nombre, '-> entrenamiento:', entrenamiento.sum(), 'registros | prueba:',
(~entrenamiento).sum(), 'registros')
```

```
80/20 -> entrenamiento: 15470 registros | prueba: 3640 registros
70/30 -> entrenamiento: 13650 registros | prueba: 5460 registros
60/40 -> entrenamiento: 11830 registros | prueba: 7280 registros
```

7. Métricas de evaluación

- **MAE:** error promedio en unidades.
- **RMSE:** como el MAE, pero castiga más los errores grandes.
- **WAPE:** error total ÷ ventas totales (en %). Es la métrica principal porque se lee fácil: "el pronóstico se equivoca X% de lo que se vende".
- **R^2:** qué tanto de la variación de las ventas explica el modelo (1 = perfecto).

In [14]:
```
def evaluar(y_real, y_pred):
    mae = mean_absolute_error(y_real, y_pred)
    rmse = np.sqrt(mean_squared_error(y_real, y_pred))
    wape = np.abs(y_real - y_pred).sum() / y_real.sum() * 100
    r2 = r2_score(y_real, y_pred)
    return {'MAE': round(mae, 2), 'RMSE': round(rmse, 2), 'WAPE (%)': round(wape, 2), 'R2':
round(r2, 3)}
```

7.1 Puntos de comparación (líneas base)

Un modelo solo sirve si le gana a lo que ya existe:

1. **Pronóstico actual de DanuStore** (`units_expected`).
2. **Modelo ingenuo:** "este mes voy a vender lo mismo que el mes pasado".

In [15]:
```
resultados = []

for nombre, corte in particiones.items():
    prueba = datos['fecha'] >= corte
    fila = evaluar(y[prueba], datos.loc[prueba, 'units_expected'])
    fila.update({'Modelo': 'Pronóstico actual (units_expected)', 'Partición': nombre,
'Hiperparámetros': '-'})
    resultados.append(fila)

    fila = evaluar(y[prueba], datos.loc[prueba, 'ventas_mes_anterior'])
    fila.update({'Modelo': 'Ingenuo (mes anterior)', 'Partición': nombre, 'Hiperparámetros': '-
'})
    resultados.append(fila)

pd.DataFrame(resultados)[['Partición', 'Modelo', 'Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)',
'R2']]
```

Out[15]:

	Partición	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
0	80/20	Pronóstico actual (units_expected)	-	1042.04	1093.44	467.95	-32.190
1	80/20	Ingenuo (mes anterior)	-	44.15	66.71	19.83	0.876
2	70/30	Pronóstico actual (units_expected)	-	1041.87	1093.51	471.23	-33.236
3	70/30	Ingenuo (mes anterior)	-	41.23	62.18	18.65	0.889
4	60/40	Pronóstico actual (units_expected)	-	1045.73	1097.63	483.00	-35.065
5	60/40	Ingenuo (mes anterior)	-	39.34	59.34	18.17	0.895

8. Modelo 1: Random Forest

Entrena muchos árboles de decisión, cada uno con una muestra aleatoria de los datos, y **promedia** sus pronósticos.

Hiperparámetros que se prueban:

- `n_estimators` : número de árboles.
- `max_depth` : profundidad máxima de cada árbol (None = sin límite).
- `min_samples_leaf` : mínimo de registros en cada hoja (evita que el árbol memorice).

In [16]:
```
configuraciones_rf = [
    {'n_estimators': 100, 'max_depth': None, 'min_samples_leaf': 1},
    {'n_estimators': 200, 'max_depth': 15,   'min_samples_leaf': 2},
    {'n_estimators': 300, 'max_depth': 8,    'min_samples_leaf': 5},
]

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    prueba = datos['fecha'] >= corte

    for config in configuraciones_rf:
        modelo = RandomForestRegressor(**config, random_state=42, n_jobs=-1)
        modelo.fit(X[entrenamiento], y[entrenamiento])
        prediccion = modelo.predict(X[prueba])

        fila = evaluar(y[prueba], prediccion)
        fila.update({'Modelo': 'Random Forest', 'Partición': nombre, 'Hiperparámetros': ',
'.join(f'{k}={v}' for k, v in config.items())})
        resultados.append(fila)

tabla_rf = pd.DataFrame(resultados)
tabla_rf[tabla_rf['Modelo'] == 'Random Forest'][['Partición', 'Hiperparámetros', 'MAE', 'RMSE',
'WAPE (%)', 'R2']]
```

Out[16]:

	Partición	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
6	80/20	n_estimators=100, max_depth=None, min_samples_leaf=1	13.10	20.34	5.88	0.989
7	80/20	n_estimators=200, max_depth=15, min_samples_leaf=2	16.00	24.26	7.18	0.984
8	80/20	n_estimators=300, max_depth=8, min_samples_leaf=5	26.74	38.35	12.01	0.959
9	70/30	n_estimators=100, max_depth=None, min_samples_leaf=1	13.16	20.54	5.95	0.988
10	70/30	n_estimators=200, max_depth=15, min_samples_leaf=2	17.03	25.47	7.70	0.981
11	70/30	n_estimators=300, max_depth=8, min_samples_leaf=5	27.09	39.06	12.25	0.956
12	60/40	n_estimators=100, max_depth=None, min_samples_leaf=1	12.96	20.15	5.98	0.988
13	60/40	n_estimators=200, max_depth=15, min_samples_leaf=2	16.99	25.15	7.85	0.981
14	60/40	n_estimators=300, max_depth=8, min_samples_leaf=5	26.93	38.89	12.44	0.955

9. Modelo 2: XGBoost

Construye árboles **uno tras otro**; cada árbol nuevo corrige los errores de los anteriores.

Hiperparámetros que se prueban:

- `n_estimators` : número de árboles.
- `learning_rate` : qué tanto corrige cada árbol (más bajo = más lento pero más cuidadoso).
- `max_depth` : profundidad máxima de cada árbol.

In [17]:
```
configuraciones_xgb = [
    {'n_estimators': 300, 'learning_rate': 0.1,  'max_depth': 6},
    {'n_estimators': 500, 'learning_rate': 0.05, 'max_depth': 4},
    {'n_estimators': 800, 'learning_rate': 0.03, 'max_depth': 8},
]

for nombre, corte in particiones.items():
    entrenamiento = datos['fecha'] < corte
    prueba = datos['fecha'] >= corte

    for config in configuraciones_xgb:
        modelo = XGBRegressor(**config, random_state=42)
        modelo.fit(X[entrenamiento], y[entrenamiento])
        prediccion = modelo.predict(X[prueba])

        fila = evaluar(y[prueba], prediccion)
        fila.update({'Modelo': 'XGBoost', 'Partición': nombre, 'Hiperparámetros': ',
'.join(f'{k}={v}' for k, v in config.items())})
        resultados.append(fila)

tabla_xgb = pd.DataFrame(resultados)
tabla_xgb[tabla_xgb['Modelo'] == 'XGBoost'][['Partición', 'Hiperparámetros', 'MAE', 'RMSE',
'WAPE (%)', 'R2']]
```

Out[17]:

	Partición	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
15	80/20	n_estimators=300, learning_rate=0.1, max_depth=6	19.73	27.08	8.86	0.980
16	80/20	n_estimators=500, learning_rate=0.05, max_depth=4	26.16	37.22	11.75	0.962
17	80/20	n_estimators=800, learning_rate=0.03, max_depth=8	13.21	18.67	5.93	0.990
18	70/30	n_estimators=300, learning_rate=0.1, max_depth=6	19.90	27.62	9.00	0.978
19	70/30	n_estimators=500, learning_rate=0.05, max_depth=4	26.17	37.36	11.84	0.960
20	70/30	n_estimators=800, learning_rate=0.03, max_depth=8	14.10	20.32	6.38	0.988
21	60/40	n_estimators=300, learning_rate=0.1, max_depth=6	19.58	26.92	9.04	0.978
22	60/40	n_estimators=500, learning_rate=0.05, max_depth=4	25.79	36.60	11.91	0.960
23	60/40	n_estimators=800, learning_rate=0.03, max_depth=8	13.52	19.12	6.24	0.989

10. Comparación de todos los modelos

In [18]:
```
tabla_final = pd.DataFrame(resultados)[['Partición', 'Modelo', 'Hiperparámetros', 'MAE',
'RMSE', 'WAPE (%)', 'R2']]
tabla_final = tabla_final.sort_values(['Partición', 'WAPE (%)']).reset_index(drop=True)
tabla_final
```

Out[18]:

	Partición	Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
0	60/40	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	12.96	20.15	5.98	0.988
1	60/40	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	13.52	19.12	6.24	0.989
2	60/40	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	16.99	25.15	7.85	0.981
3	60/40	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	19.58	26.92	9.04	0.978
4	60/40	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	25.79	36.60	11.91	0.960
5	60/40	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	26.93	38.89	12.44	0.955
6	60/40	Ingenuo (mes anterior)	-	39.34	59.34	18.17	0.895
7	60/40	Pronóstico actual (units_expected)	-	1045.73	1097.63	483.00	-35.065
8	70/30	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.16	20.54	5.95	0.988
9	70/30	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	14.10	20.32	6.38	0.988
10	70/30	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	17.03	25.47	7.70	0.981
11	70/30	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	19.90	27.62	9.00	0.978
12	70/30	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	26.17	37.36	11.84	0.960
13	70/30	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	27.09	39.06	12.25	0.956
14	70/30	Ingenuo (mes anterior)	-	41.23	62.18	18.65	0.889
15	70/30	Pronóstico actual (units_expected)	-	1041.87	1093.51	471.23	-33.236
16	80/20	Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.10	20.34	5.88	0.989
17	80/20	XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	13.21	18.67	5.93	0.990
18	80/20	Random Forest	n_estimators=200, max_depth=15, min_samples_leaf=2	16.00	24.26	7.18	0.984
19	80/20	XGBoost	n_estimators=300, learning_rate=0.1, max_depth=6	19.73	27.08	8.86	0.980
20	80/20	XGBoost	n_estimators=500, learning_rate=0.05, max_depth=4	26.16	37.22	11.75	0.962
21	80/20	Random Forest	n_estimators=300, max_depth=8, min_samples_leaf=5	26.74	38.35	12.01	0.959
22	80/20	Ingenuo (mes anterior)	-	44.15	66.71	19.83	0.876
23	80/20	Pronóstico actual (units_expected)	-	1042.04	1093.44	467.95	-32.190

In [19]:
```
# Mejor configuración de cada modelo (menor WAPE) en la partición 70/30
mejores = tabla_final[tabla_final['Partición'] ==
'70/30'].groupby('Modelo').first().sort_values('WAPE (%)')
mejores[['Hiperparámetros', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
```

Out[19]:

Modelo	Hiperparámetros	MAE	RMSE	WAPE (%)	R2
Random Forest	n_estimators=100, max_depth=None, min_samples_leaf=1	13.16	20.54	5.95	0.988
XGBoost	n_estimators=800, learning_rate=0.03, max_depth=8	14.10	20.32	6.38	0.988
Ingenuo (mes anterior)	-	41.23	62.18	18.65	0.889
Pronóstico actual (units_expected)	-	1041.87	1093.51	471.23	-33.236

11. Mejor modelo: resultados

Se vuelve a entrenar el mejor modelo con la partición 70/30 para ver sus resultados con gráficas.

In [20]:
```
corte = '2025-07-01'
entrenamiento = datos['fecha'] < corte
prueba = datos['fecha'] >= corte

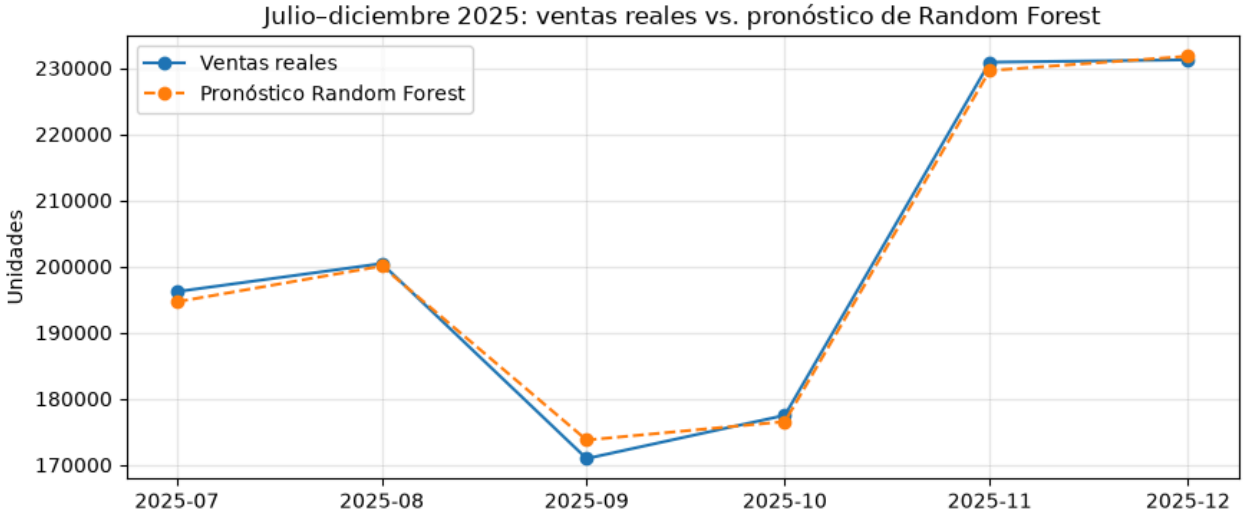
mejor_rf = RandomForestRegressor(n_estimators=100, max_depth=None, min_samples_leaf=1,
random_state=42, n_jobs=-1)
mejor_rf.fit(X[entrenamiento], y[entrenamiento])

resultado = datos.loc[prueba, ['fecha', 'region', 'units_sold', 'units_expected']].copy()
resultado['pronostico_rf'] = mejor_rf.predict(X[prueba])

# Total por mes: real vs. pronóstico del modelo vs. pronóstico actual
total_mes = resultado.groupby('fecha')[['units_sold', 'pronostico_rf', 'units_expected']].sum()

plt.figure(figsize=(10, 4))
plt.plot(total_mes.index, total_mes['units_sold'], marker='o', label='Ventas reales')
plt.plot(total_mes.index, total_mes['pronostico_rf'], marker='o', linestyle='--',
label='Pronóstico Random Forest')
plt.title('Julio–diciembre 2025: ventas reales vs. pronóstico de Random Forest')
plt.ylabel('Unidades')
plt.legend()
plt.grid(alpha=0.3)
plt.show()

# El pronóstico actual no se grafica porque es ~6 veces mayor y aplastaría la escala
total_mes['diferencia_rf'] = total_mes['pronostico_rf'] - total_mes['units_sold']
total_mes['diferencia_actual'] = total_mes['units_expected'] - total_mes['units_sold']
total_mes.round(0)
```



Out[20]:

fecha	units_sold	pronostico_rf	units_expected	diferencia_rf	diferencia_actual
2025-07-01	196192	194651.0	1145864	-1541.0	949672
2025-08-01	200436	200050.0	1146348	-386.0	945912
2025-09-01	170951	173754.0	1156597	2803.0	985646
2025-10-01	177498	176540.0	1145364	-958.0	967866
2025-11-01	230877	229613.0	1150628	-1264.0	919751
2025-12-01	231237	231779.0	1151011	542.0	919774

In [21]:
```
# Valores reales vs. estimados y residuales (error = real - estimado)
resultado['residual'] = resultado['units_sold'] - resultado['pronostico_rf']

fig, ax = plt.subplots(1, 3, figsize=(15, 4))

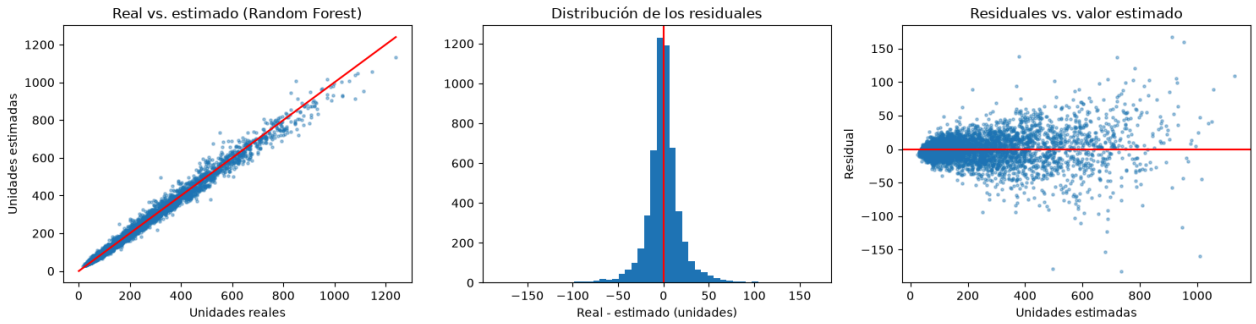
# 1) Real vs. estimado: si el modelo fuera perfecto, todos los puntos caerían en la línea roja
ax[0].scatter(resultado['units_sold'], resultado['pronostico_rf'], s=5, alpha=0.4)
maximo = resultado['units_sold'].max()
ax[0].plot([0, maximo], [0, maximo], color='red')
ax[0].set_title('Real vs. estimado (Random Forest)')
ax[0].set_xlabel('Unidades reales')
ax[0].set_ylabel('Unidades estimadas')

# 2) Distribución de los residuales: deberían estar centrados en 0
ax[1].hist(resultado['residual'], bins=50)
ax[1].axvline(0, color='red')
ax[1].set_title('Distribución de los residuales')
ax[1].set_xlabel('Real - estimado (unidades)')

# 3) Residuales vs. estimado: no debería haber un patrón
ax[2].scatter(resultado['pronostico_rf'], resultado['residual'], s=5, alpha=0.4)
ax[2].axhline(0, color='red')
ax[2].set_title('Residuales vs. valor estimado')
ax[2].set_xlabel('Unidades estimadas')
ax[2].set_ylabel('Residual')

plt.tight_layout()
plt.show()

print('Residual promedio:', round(resultado['residual'].mean(), 2), 'unidades')
print('El 90% de los errores está entre', round(resultado['residual'].quantile(0.05), 1), 'y',
round(resultado['residual'].quantile(0.95), 1), 'unidades')
```



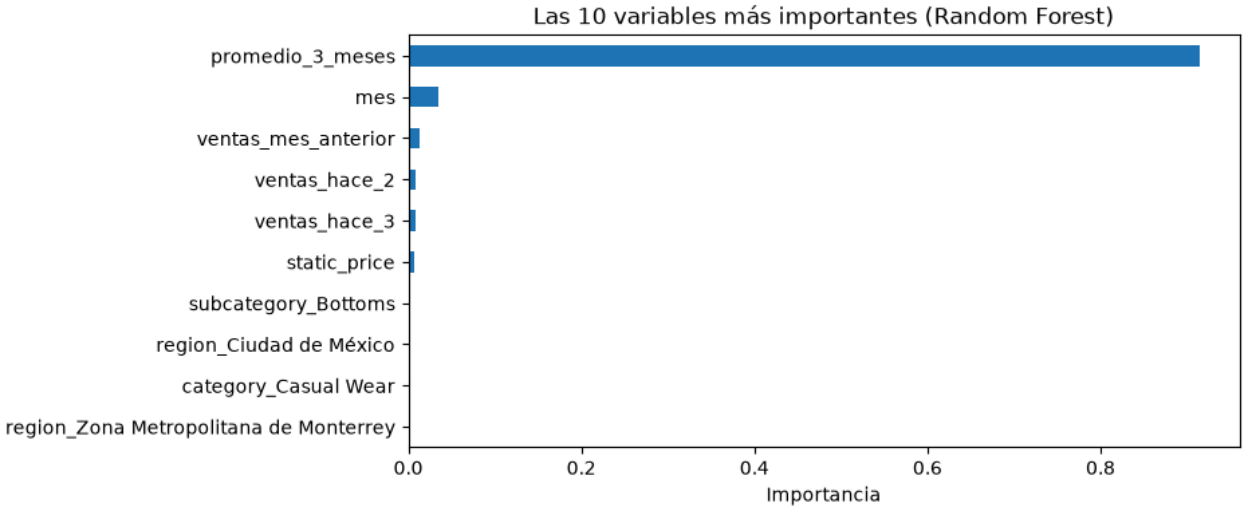

```
Residual promedio: 0.15 unidades
El 90% de los errores está entre -29.5 y 31.2 unidades
```

In [22]:
```
# Error del mejor modelo por región
por_region = resultado.groupby('region').apply(
    lambda g: round(np.abs(g['units_sold'] - g['pronostico_rf']).sum() / g['units_sold'].sum()
* 100, 2))
print('WAPE (%) del Random Forest por región:')
print(por_region.sort_values())
```

```
WAPE (%) del Random Forest por región:
region
Ciudad de México                    5.20
Zona Metropolitana de Monterrey     5.72
Zona Metropolitana de Guadalajara   5.97
Bajío                               6.59
Noroeste                            7.30
Sur                                 7.44
Sureste                             7.73
dtype: float64
```

In [23]:
```
# ¿Qué variables usa más el modelo? (segundo método de selección de variables)
importancia = pd.Series(mejor_rf.feature_importances_,
index=X.columns).sort_values(ascending=False).head(10)
```

```
plt.figure(figsize=(8, 4))
importancia.sort_values().plot(kind='barh')
plt.title('Las 10 variables más importantes (Random Forest)')
plt.xlabel('Importancia')
plt.show()
```



12. Impacto del preprocesamiento

Para medir qué tanto ayudó la preparación de los datos, se entrenan los dos modelos (partición 70/30, mejores hiperparámetros) con **4 grupos de variables**:

1. **Básicas:** región, categoría, subcategoría y mes (codificadas con One-Hot).
2. **Básicas + precio.**
3. **Básicas + ventas pasadas** (las variables creadas en el preprocesamiento).
4. **Todas** (el modelo final).

In [24]:
```
corte = '2025-07-01'
entrenamiento = datos['fecha'] < corte
prueba = datos['fecha'] >= corte

basicas = ['region', 'category', 'subcategory', 'mes']
rezagos = ['ventas_mes_anterior', 'ventas_hace_2', 'ventas_hace_3', 'promedio_3_meses']
grupos = {
    '1. Básicas': basicas,
    '2. Básicas + precio': basicas + ['static_price'],
    '3. Básicas + ventas pasadas': basicas + rezagos,
    '4. Todas (modelo final)': basicas + ['static_price'] + rezagos,
}
modelos = {
    'Random Forest': lambda: RandomForestRegressor(n_estimators=100, random_state=42,
n_jobs=-1),
    'XGBoost': lambda: XGBRegressor(n_estimators=800, learning_rate=0.03, max_depth=8,
random_state=42),
}

comparacion = []
for nombre_modelo, crear_modelo in modelos.items():
    for nombre_grupo, columnas in grupos.items():
        X_grupo = pd.get_dummies(datos[columnas], columns=['region', 'category',
'subcategory'], dtype=int)
        modelo = crear_modelo()
        modelo.fit(X_grupo[entrenamiento], y[entrenamiento])
        fila = evaluar(y[prueba], modelo.predict(X_grupo[prueba]))
        fila.update({'Modelo': nombre_modelo, 'Variables': nombre_grupo})
        comparacion.append(fila)
```

```
pd.DataFrame(comparacion)[['Modelo', 'Variables', 'MAE', 'RMSE', 'WAPE (%)', 'R2']]
```

Out[24]:

	Modelo	Variables	MAE	RMSE	WAPE (%)	R2
0	Random Forest	1. Básicas	50.10	77.38	22.66	0.829
1	Random Forest	2. Básicas + precio	13.31	20.88	6.02	0.988
2	Random Forest	3. Básicas + ventas pasadas	13.42	20.92	6.07	0.987
3	Random Forest	4. Todas (modelo final)	13.16	20.54	5.95	0.988
4	XGBoost	1. Básicas	50.09	77.34	22.66	0.829
5	XGBoost	2. Básicas + precio	16.60	23.21	7.51	0.985
6	XGBoost	3. Básicas + ventas pasadas	15.42	21.84	6.97	0.986
7	XGBoost	4. Todas (modelo final)	14.10	20.32	6.38	0.988

Interpretación:

- Con solo las variables **básicas** el error es alto: el modelo sabe la región, la categoría y el mes, pero no sabe cuánto vende cada producto en particular.
- Al agregar el **precio**, el error baja muchísimo. Cada producto tiene un precio único, así que el precio funciona como "identificador" del producto, y como **las ventas de 2025 repiten las de 2024**, el modelo puede "recordar" cuánto vendió ese producto en el mismo mes del año pasado. Es un buen resultado, pero depende de que los datos se repitan.
- Al agregar las **ventas pasadas** (creadas en el preprocesamiento), el error también baja mucho **sin necesidad de identificar el producto**: el modelo aprende del nivel de ventas reciente, lo cual es más útil si en el futuro las ventas cambian o entran productos nuevos.
- Por eso el modelo final usa **todas** las variables.

13. Conclusiones

¿Qué modelo y qué división funcionaron mejor?

Partición	Random Forest (mejor)	XGBoost (mejor)	Ingenuo	Pronóstico actual
80/20	**5.88 %**	5.93 %	19.8 %	468 %
70/30	**5.95 %**	6.38 %	18.7 %	471 %
60/40	**5.98 %**	6.24 %	18.2 %	483 %

(WAPE: error total ÷ ventas totales)

- **El mejor modelo es Random Forest** (100 árboles, sin límite de profundidad). Tiene el menor WAPE en las tres particiones, un MAE de ~13 unidades y un $R^2 \approx 0.99$. XGBoost queda muy cerca, lo que confirma que el patrón en los datos es real.
- **La mejor división es 80/20**, aunque la diferencia entre particiones es mínima (5.88 % a 5.98 %). El modelo es **estable**: incluso entrenando con solo 13 meses (60/40) el error casi no cambia.
- **Los dos modelos le ganan por mucho al pronóstico actual** (~470 % de error, porque siempre espera ~6 veces más de lo que se vende) y al modelo ingenuo (~19 %).
- **Residuales:** están centrados en 0 (residual promedio ≈ 0.15 unidades) y el 90 % de los errores está entre −30 y +31 unidades. No hay un patrón claro, es decir, el modelo no sobrestima ni subestima de forma sistemática.

¿Qué impacto tuvo el preprocesamiento?

- **Crear las ventas pasadas** fue lo más importante. Con solo región, categoría, subcategoría y mes el error es de **22.7 %**; con las ventas pasadas baja a **6.1 %** en Random Forest y a 7.0 % en XGBoost.
- **El One-Hot Encoding** permitió usar región, categoría y subcategoría, que son texto.

- **Excluir las variables con fuga** (Ventas_Acumuladas, Venta_Promedio_Diaria, Cumplimiento, etc.) evita un modelo "perfecto" pero inútil en la vida real.
- **La normalización no fue necesaria** porque los modelos de árboles no dependen de la escala.

¿Qué impacto tuvo el ajuste de hiperparámetros?

- **Random Forest:** limitar la profundidad (`max_depth` = 8 y `min_samples_leaf` = 5) duplicó el error, de 5.95 % a 12.25 %. Los árboles completos distinguen mejor entre productos y regiones.
- **XGBoost:** fue más sensible. Con `max_depth` = 4 el error fue de 11.8 %, y con 800 árboles, `learning_rate` = 0.03 y `max_depth` = 8 bajó a 6.4 %. Es decir, el ajuste redujo el error casi a la mitad.

Beneficio para DanuStore: puede planear su stock según lo que realmente se va a vender en cada región y mes, en lugar de un pronóstico plano e inflado, y así reducir el sobreinventario (hoy el stock alcanza para ~208 días en lugar de ~34). Las variables más importantes son el promedio de ventas de los últimos 3 meses y el mes (temporada de noviembre y diciembre).

Limitantes:

1. **Las ventas de 2025 repiten casi exactamente las de 2024** (76.6 % de los registros son idénticos). Esto hace que el pronóstico sea más fácil de lo normal, por lo que hay que validar el modelo con datos nuevos antes de usarlo.
2. Las ventas son solo de clientes registrados.
3. El modelo pronostica **un mes adelante**; para varios meses habría que usar sus propios pronósticos como entrada.